Detecção de Anomalias em Telemetria de Sistemas Utilizando Redes de Hopfield

Trabalho de Implementação de Redes Neurais Artificiais
Tema: Redes baseadas em Memória Associativa (Redes Neurais Recorrentes)

[a preencher: nome do integrante 1]
[a preencher: nome do integrante 2]
[a preencher: nome do integrante 3]

[a preencher: instituição, curso e disciplina]

6 de novembro de 2026

Resumo

Este relatório apresenta o projeto de um detector de anomalias em telemetria de sistemas baseado em redes de Hopfield, o modelo clássico de memória associativa recorrente. O problema é tratado como classificação binária (normal × anômalo) sobre métricas de utilização e atividade de máquinas servidoras (carga de CPU, uso de memória e de rede, entre outras). Usamos o *Server Machine Dataset* (SMD): 28 máquinas, 38 métricas amostradas por minuto e 708.420 pontos de teste, dos quais 4,16 % são anômalos. A abordagem armazena na matriz de pesos protótipos do funcionamento normal (regras de Hebb e de Storkey), recupera cada observação por dinâmica assíncrona e usa distância de Hamming e energia como escores de anomalia; a rede de Hopfield moderna (Ramsauer et al.) entra como variante. O texto cobre a teoria (energia, convergência, capacidade, estados espúrios), a análise dos dados, o protocolo experimental (divisões cronológicas, métricas, linhas de base clássicas e o protocolo com LLM da Etapa II) e uma comparação crítica a priori. Os resultados experimentais ainda não foram obtidos: as tabelas correspondentes estão marcadas como lacunas a preencher.

Palavras-chave: redes de Hopfield; memória associativa; detecção de anomalias; telemetria de sistemas; classificação binária; *Server Machine Dataset*.

Sumário

1 Introdução **4**
- 1.1 Contexto e motivação . . . 4
- 1.2 Objetivos . . . 4
- 1.3 Pergunta de pesquisa . . . 5
- 1.4 Escopo e premissas . . . 5
- 1.5 Organização do texto . . . 5

2 Fundamentação teórica **5**
- 2.1 Memória associativa e redes recorrentes . . . 6
- 2.2 A rede de Hopfield discreta . . . 6
- 2.3 Armazenamento: regras de Hebb e de Storkey . . . 7
- 2.4 Capacidade, estados espúrios e bacias de atração . . . 8
- 2.5 Rede contínua e a formulação de Hopfield e Tank . . . 8
- 2.6 Redes de Hopfield modernas . . . 9
- 2.7 A rede de Hopfield como detector de anomalias . . . 10

3 Descrição do problema e dos dados **10**
- 3.1 Definição do problema . . . 10
- 3.2 O conjunto de dados SMD . . . 11
- 3.3 Três exemplos reais . . . 12
- 3.4 Exploração dos dados: atributos constantes e deriva . . . 13
- 3.5 Adequação ao tema e limitações do conjunto . . . 13

4 Metodologia **14**
- 4.1 Visão geral . . . 14
- 4.2 Preparação e limpeza . . . 14
- 4.3 Codificação binária em termômetro . . . 15
- 4.4 Memória de protótipos . . . 16
- 4.5 Recuperação e escores de anomalia . . . 16
- 4.6 Linhas de base . . . 16
- 4.7 Divisão dos dados e protocolos de avaliação . . . 17
- 4.8 Balanceamento de classes . . . 19
- 4.9 Métricas de avaliação . . . 19
- 4.10 Experimentos e hipóteses . . . 20
- 4.11 Etapa II: LLM *versus* modelos clássicos . . . 20
- 4.12 Reprodutibilidade . . . 21

5 Resultados **21**
- 5.1 E1: capacidade e recuperação . . . 21
- 5.2 E2: detecção de anomalias . . . 22
- 5.3 Ablações do detector de Hopfield . . . 22
- 5.4 E3: Etapa II — LLM *versus* modelos clássicos . . . 22
- 5.5 E4 (opcional): interpretabilidade . . . 22

6 Comparação crítica **24**
6.1 Hipóteses e evidência necessária . . . 24
6.2 Pontos positivos e negativos . . . 25
6.3 Síntese a priori . . . 26

7 Conclusões **26**
7.1 O que já pode ser afirmado . . . 26
7.2 O que depende dos experimentos . . . 26
7.3 Limitações . . . 27
7.4 Próximos passos . . . 27

Referências **28**

A Pseudocódigos e notas de implementação **29**

B Exemplo numérico com 5 neurônios **31**

C *Prompt* e registro da Etapa II **32**
C.1 Mensagens . . . 32
C.2 Serialização das observações . . . 33
C.3 Regras de execução . . . 33
C.4 Registro da execução . . . 34

D Cronograma proposto **34**

E Conformidade com o enunciado **35**

F Derivações **36**
F.1 Energia de Hebb em função das sobreposições . . . 36
F.2 Ruído cruzado da regra de Hebb . . . 37
F.3 A energia da rede moderna como mínimo suave . . . 37
F.4 Padrões binários: distância de Hamming e separação . . . 37
F.5 Distância de Hamming na codificação em termômetro . . . 38

G Dados por máquina e divisão cronológica **38**

1 Introdução

1.1 Contexto e motivação

Sistemas operacionais e servidores expõem continuamente contadores de utilização e de atividade em baixo nível — carga de CPU, uso de memória, tráfego de rede, entre outros. Essa *telemetria* é a base do monitoramento: quando o comportamento de uma máquina se afasta do habitual (um vazamento de memória, um processo descontrolado, uma falha de rede), o desvio aparece nas métricas antes de se tornar uma interrupção visível. Detectar automaticamente esses desvios é o problema clássico de *detecção de anomalias* [3].

A dificuldade prática é dupla. Primeiro, anomalias são raras e heterogêneas: nos dados deste trabalho apenas 4,16 % dos pontos de teste são anômalos (Seção 3), de modo que é impossível enumerar de antemão todas as formas de falha. Segundo, o rótulo "anômalo" costuma vir de relatórios de incidentes, ao passo que o comportamento *normal* está disponível em abundância e sem rótulo. Isso favorece abordagens que *aprendem o que é normal* e tratam como anomalia aquilo que não se encaixa.

As redes de Hopfield [7] são um ajuste natural a essa ideia. Trata-se de uma rede neural recorrente totalmente conectada, cujo estado evolui, sob pesos simétricos, até um mínimo local de uma função de energia. Os padrões gravados na matriz de pesos tornam-se atratores, e apresentar à rede uma entrada parcial ou ruidosa a faz convergir para o padrão armazenado mais próximo [9]. Se os padrões armazenados descrevem o funcionamento normal, esperamos que uma observação normal seja "corrigida" para um padrão familiar com pouco esforço, enquanto uma observação anômala permaneça distante de qualquer atrator ou seja atraída para um estado que não corresponde a nenhuma memória. Essa diferença na recuperação pode ser convertida em um escore de anomalia. A ideia é uma hipótese de trabalho, não um resultado: avaliá-la é o objetivo do projeto.

1.2 Objetivos

Objetivo geral. Avaliar a capacidade de uma rede de Hopfield de armazenar padrões de funcionamento normal e reconhecer comportamentos que se desviam desses padrões, tratando a detecção de anomalias em telemetria de sistemas como um problema de classificação binária (normal × anômalo).

Objetivos específicos.

1. Revisar o modelo de Hopfield em suas formas discreta, contínua (Hopfield–Tank) e moderna (Ramsauer et al.), com foco em energia, convergência, capacidade e estados espúrios.
2. Formalizar um detector *one-class* baseado em recuperação associativa, com escores definidos a partir de distância de Hamming e de energia.
3. Caracterizar o conjunto de dados (SMD): amostras, atributos, rótulos, desbalanceamento e deriva.
4. Definir o protocolo experimental: preparação, codificação binária, divisões cronológicas, métricas e linhas de base clássicas (Etapa I).
5. Definir o protocolo da Etapa II (LLM com *zero-shot* e *few-shot*) sobre os mesmos dados.
6. Formular hipóteses verificáveis e critérios para a comparação crítica dos resultados.

1.3 Pergunta de pesquisa

Uma memória associativa de Hopfield, treinada somente com telemetria predominantemente normal, separa pontos normais de pontos anômalos? E como esse desempenho se compara ao de classificadores clássicos e ao de um LLM usado por prompting*?*

1.4 Escopo e premissas

Escopo desta versão do relatório

- **Projeto e fundamentação, sem experimentos.** Este texto não contém resultados de modelos. As tabelas da Seção 5 têm células vazias (···) a preencher após os experimentos; nenhum valor foi inventado. Os números das Seções 3 e 4 são estatísticas reais do SMD (contagens, divisões e exploração dos dados) e estão identificados como tais.
- **Hopfield não consta da lista do enunciado.** Para classificação, o enunciado cita *Decision Trees*, *Random Forest*, *Naive Bayes*, SVM, MLP, XGBoost e KNN [20]. Adotamos a rede de Hopfield como *modelo do tema* e *Random Forest* e SVM como linhas de base (mínimo de 2 modelos da Etapa I). **Confirmar este arranjo com o professor.**
- **"Baixo nível" no SMD.** São 38 contadores anonimizados de utilização de recursos, sem chamadas de sistema nem rastros de *kernel*. Coletar telemetria própria é trabalho futuro (Seção 7).
- **Etapa II é um protocolo.** A execução exige acesso a um modelo de linguagem; aqui documentamos tarefa, *prompt*, amostragem e métricas (Apêndice C).
- **Propostas, não resultados.** Divisões, hiperparâmetros e linhas de base são decisões de projeto a validar; as derivações próprias estão sinalizadas como tais.

1.5 Organização do texto

A Seção 2 apresenta a fundamentação teórica. A Seção 3 define o problema e descreve o conjunto de dados, e a Seção 4 detalha a metodologia, incluindo as Etapas I e II. A Seção 5 reserva as tabelas de resultados, a Seção 6 traz a comparação crítica (hipóteses e pontos positivos e negativos) e a Seção 7 fecha com conclusões e próximos passos. Os apêndices reúnem pseudocódigo, um exemplo numérico, o *prompt*, o cronograma, o mapeamento dos requisitos do enunciado, derivações e a tabela das 28 máquinas.

2 Fundamentação teórica

Usamos N para o número de neurônios (dimensão do estado) e K para o número de padrões armazenados.[1] As fontes principais são a bibliografia indicada pelo professor — Hopfield e Tank [9], o verbete da Wikipédia [21] e Ramsauer et al. [16] — e, quando necessário, as obras originais por elas citadas. Derivações próprias estão sinalizadas como tais.

[1] Ramsauer et al. [16] usam d para a dimensão e N para o número de padrões; as fórmulas deles são reescritas aqui na nossa notação.

2.1 Memória associativa e redes recorrentes

Uma memória endereçável por conteúdo (*content-addressable memory*, CAM) recupera um item completo a partir de uma parte dele ou de uma versão ruidosa, em vez de acessá-lo por endereço. Hopfield [7] mostrou que uma rede recorrente de elementos de limiar com conexões simétricas realiza essa função: a recuperação é a evolução dinâmica de um estado inicial (a "chave") até um estado estável, interpretado como a memória evocada. Em Hopfield e Tank [9, p. 144], cada recuperação "resolve o problema" de qual das palavras binárias armazenadas é a mais próxima da chave. É essa propriedade — identificar o padrão normal mais próximo — que exploramos como detector de anomalias.

2.2 A rede de Hopfield discreta

Definição 2.1 (Rede de Hopfield discreta)**.** Uma rede de Hopfield discreta com N neurônios é definida por uma matriz de pesos simétrica $W \in \mathbb{R}^{N\times N}$ ($w_{ij} = w_{ji}$) com diagonal nula ($w_{ii} = 0$) e por limiares $\theta \in \mathbb{R}^N$. O estado é $s \in \{-1, +1\}^N$, o campo local do neurônio i é $h_i(s) = \sum_j w_{ij} s_j$ e sua atualização é

$$s_i \leftarrow \begin{cases} +1, & h_i(s) \geq \theta_i, \\ -1, & \text{caso contrário.} \end{cases} \tag{2.1}$$

Essa é a formulação da Wikipédia [21]: unidades ± 1, sem autoconexões, pesos simétricos e limiares em geral nulos e não treinados. A rede é um grafo completo não direcionado (Figura 1). A atualização pode ser *assíncrona* (um neurônio por vez, em ordem aleatória ou fixa) ou *síncrona* (todos de uma vez, o que exige um relógio central) [21]. A cada estado associa-se a energia

$$E(s) = -\tfrac{1}{2} \sum_{i,j} w_{ij} s_i s_j + \sum_i \theta_i s_i = -\tfrac{1}{2}\, s^\top W s + \theta^\top s. \tag{2.2}$$

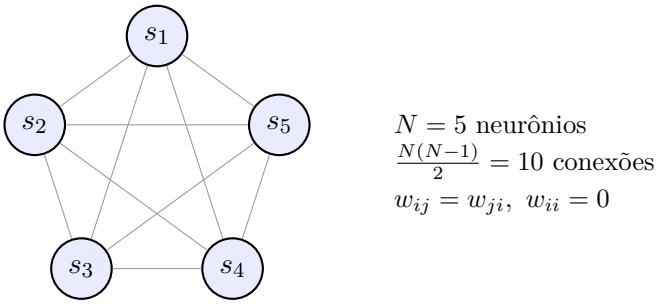


Figura 1. Rede de Hopfield com $N = 5$ neurônios: grafo completo não direcionado, sem autoconexões.

Proposição 2.2 (Convergência assíncrona)**.** *Se W é simétrica com diagonal nula, cada atualização assíncrona não aumenta E e o número de mudanças de estado é finito. Assim, varreduras sucessivas (em ordem fixa ou aleatória) terminam em um ponto fixo, que é um mínimo local de E em relação a mudanças de um único neurônio.*

Demonstração. Seja k o neurônio atualizado e s' o estado resultante. Como $w_{kk} = 0$ e W é simétrica, apenas os termos de E que envolvem s_k mudam, e

$$E(s') - E(s) = -(s'_k - s_k)(h_k(s) - \theta_k).$$

Se $s'_k \neq s_k$ e $h_k > \theta_k$, então $s'_k = +1$, $s_k = -1$ e a variação é $-2(h_k - \theta_k) < 0$; se $h_k < \theta_k$, então $s'_k = -1$, $s_k = +1$ e a variação é $2(h_k - \theta_k) < 0$. O único caso sem queda estrita é o empate

$h_k = \theta_k$, em que a regra (2.1) só permite a transição $-1 \to +1$. Como há 2^N estados, E assume um número finito de valores e só cai estritamente um número finito de vezes. Entre duas quedas estritas consecutivas ocorrem no máximo N transições por empate, pois cada neurônio só pode ir de -1 para $+1$ uma vez sem que haja queda estrita. Logo o número total de mudanças é finito. □

Observação 2.3 (Dinâmica síncrona). Com atualização síncrona a monotonicidade de E não vale. Para $W = \left(\begin{smallmatrix} 0 & -1 \\ -1 & 0 \end{smallmatrix}\right)$ e $\theta = 0$, o estado $(+1, +1)$ vai para $(-1, -1)$ e volta, num ciclo de período 2, ao passo que a atualização assíncrona leva a $(-1, +1)$, que é ponto fixo. Bruck [1] provou um teorema de convergência generalizado que cobre as dinâmicas assíncrona e síncrona [21]. Neste trabalho usamos a dinâmica assíncrona.

2.3 Armazenamento: regras de Hebb e de Storkey

Regra de Hebb. Dados K padrões $\xi^1, \dots, \xi^K \in \{-1, +1\}^N$,

$$w_{ij} = \frac{1}{N} \sum_{\mu=1}^{K} \xi_i^\mu \xi_j^\mu \quad (i \neq j), \qquad w_{ii} = 0, \qquad \theta = 0. \tag{2.3}$$

Neurônios que têm o mesmo valor nos padrões ganham peso positivo, e os de valores opostos, peso negativo [21]. A regra é *local* (o peso w_{ij} depende apenas da atividade de i e j) e *incremental* (um novo padrão é somado sem revisitar os anteriores). Hopfield e Tank [9, p. 145] chegam a $T_{ij} = \sum_s V_i^s V_j^s$, igual a (2.3) a menos de um fator positivo e de uma constante aditiva na energia.[2]

Aplicando a rede a um padrão armazenado ξ^ν, o campo local se decompõe em sinal e ruído cruzado:

$$h_i(\xi^\nu) = \underbrace{\tfrac{N-1}{N}\,\xi_i^\nu}_{\text{sinal}} + \underbrace{\tfrac{1}{N} \sum_{\mu \neq \nu} \sum_{j \neq i} \xi_i^\mu \xi_j^\mu \xi_j^\nu}_{\text{ruído cruzado}}.$$

Para padrões independentes e não viesados, o ruído cruzado tem média nula e variância $\approx (K-1)/N$: enquanto K/N é pequeno, o sinal domina e o padrão é estável (argumento padrão; ver Hertz et al. [6]). Daí a importância da razão K/N na Seção 2.4.

Regra de Storkey. Introduzida em 1997 [18], também é local e incremental e, segundo o autor, confere à rede capacidade maior que a da regra de Hebb [21]. Com $W^0 = 0$ e N neurônios,

$$w_{ij}^\nu = w_{ij}^{\nu-1} + \tfrac{1}{N}\xi_i^\nu \xi_j^\nu - \tfrac{1}{N}\xi_i^\nu h_{ji}^\nu - \tfrac{1}{N}\xi_j^\nu h_{ij}^\nu, \qquad h_{ij}^\nu = \sum_{k \neq i,j} w_{ik}^{\nu-1} \xi_k^\nu, \tag{2.4}$$

em que h_{ij}^ν é um campo local que exclui as contribuições de i e j. *Interpretação nossa:* os termos de campo local subtraem do incremento a parte que os pesos já acumulados "predizem" para o novo padrão, o que reduz o ruído cruzado. Em forma matricial, com $u = W^{\nu-1}\xi^\nu$ e a diagonal zerada após cada passo,

$$W^\nu = W^{\nu-1} + \tfrac{1}{N}\left(\xi^\nu \xi^{\nu\top} - \xi^\nu u^\top - u\,\xi^{\nu\top} + 2W^{\nu-1}\right),$$

[2] A Wikipédia [21] normaliza pelo número de padrões. Como o fator positivo não altera o sinal de h_i quando $\theta = 0$, a escolha é irrelevante para a dinâmica; usamos $1/N$ para que a energia se escreva em função das sobreposições (Apêndice F).

forma que verificamos numericamente contra a recursão (2.4) (Apêndice A).

2.4 Capacidade, estados espúrios e bacias de atração

Capacidade. No espaço de dimensão N, o modelo padrão armazena apenas $\sim CN/\log N$ padrões aleatórios sem erros, com $C < 1/2$ para que um padrão fixo seja estável e $C < 1/4$ para que todos o sejam (McEliece et al. [12], conforme relatado em [16]). Aceitando pequenos erros de recuperação, a capacidade é de cerca de $0{,}138N$ [6, 21, 16]. A Wikipédia dá ainda $C \simeq N/(2\ln N)$ para a regra de Hebb e $C \simeq N/\sqrt{2\ln N}$ para a de Storkey [21]. A Tabela 1 avalia essas expressões para os tamanhos de rede que surgem na Seção 4.3.

Tabela 1. Capacidades teóricas aproximadas (padrões aleatórios, independentes e não viesados). Valores calculados pelas fórmulas citadas; são ordens de grandeza, não garantias, para N desta faixa.

N	$0{,}138\,N$ (Hebb, com pequenos erros)	$N/(2\ln N)$ (Hebb)	$N/\sqrt{2\ln N}$ (Storkey)
67	9,2	8,0	23,1
122	16,8	12,7	39,4
224	30,9	20,7	68,1
412	56,9	34,2	118,7

Estados espúrios. Os padrões armazenados são atratores, mas a rede também pode convergir para estados que não são memórias [21]. Com $\theta = 0$, $E(s) = E(-s)$, de modo que $-\xi^\mu$ é sempre um estado espúrio com a mesma energia de ξ^μ; combinações lineares de um número ímpar de padrões também podem ser pontos fixos [21]. O número de mínimos espúrios é exponencial na dimensão [16, 2], mesmo para padrões ortogonais [21]. Para um detector de anomalias isso é um risco concreto: uma observação anômala atraída por um estado espúrio termina com energia baixa e pode parecer familiar (Apêndice B).

Bacias de atração. A bacia de um atrator é o conjunto de estados iniciais que convergem para ele. Seu tamanho determina a tolerância a ruído da recuperação; no nosso caso, define o quanto uma observação normal pode variar sem ser tratada como anomalia.

2.5 Rede contínua e a formulação de Hopfield e Tank

Hopfield e Tank [9] usam neurônios de resposta graduada, $V_i = g(u_i)$ com g sigmoide, e dinâmica

$$\frac{du_i}{dt} = -\frac{u_i}{\tau} + \sum_j T_{ij} V_j + I_i \qquad \text{(Eq. 3 do artigo)}, \tag{2.5}$$

em que T_{ij} são as conexões e I_i correntes de polarização. Com T simétrica o sistema converge a estados estáveis [8, 9], que no limite de alto ganho são os mínimos locais de

$$E = -\tfrac{1}{2}\sum_i \sum_j T_{ij} V_i V_j - \sum_i V_i I_i \qquad \text{(Eq. 4)}, \tag{2.6}$$

situados nos vértices do hipercubo [9].

A CAM como problema de otimização. Na CAM (pp. 144–145) as saídas valem ± 1 e a memória é uma palavra binária; a recuperação coloca as saídas no padrão da chave e deixa

o sistema convergir. Para que os mínimos de E sejam as memórias V^s, os autores propõem $E = -\frac{1}{2}\sum_s (V^s \cdot V)^2$ (Eq. 5), que tem mínimos de profundidade $\approx -\frac{1}{2}N^2$ em cada memória, e mostram que isso equivale a (2.6) com $I_i = 0$ e $T_{ij} = \sum_s V_i^s V_j^s$. Na p. 145 observam também que, numa CAM prática (por exemplo, para guardar números de telefone), é preciso uma transformação que codifique a informação do mundo real na representação binária da memória. Esse é o papel da codificação em termômetro da Seção 4.3.

O caixeiro-viajante. Os autores mapeiam o problema em n^2 neurônios (a posição de cada cidade no percurso), com termos de energia para as restrições e para a distância. Com 10 cidades, de 20 estados iniciais aleatórios 16 convergiram para percursos válidos, e cerca de 50 % das tentativas produziram um dos 2 menores percursos; com 30 cidades (900 neurônios) a escolha de parâmetros "parece ser uma questão mais delicada" do que com 100 neurônios [9, p. 148]. Para este trabalho, a lição é dupla: mapear o problema na rede é parte central do modelo, e a qualidade do resultado depende de sintonia de parâmetros que se agrava com o tamanho. Não usamos a dinâmica analógica nem otimização combinatória; usamos a rede apenas como memória associativa.

2.6 Redes de Hopfield modernas

Krotov e Hopfield [11] trocaram o termo quadrático da energia por uma função de crescimento mais rápido ($F(x) = x^n$), obtendo capacidade proporcional a N^{n-1}; Demircigil et al. [4] usaram energia exponencial, com capacidade exponencial em N [21]. Ramsauer et al. [16] generalizam para estados contínuos $\xi \in \mathbb{R}^N$ e padrões nas colunas de $X = (x_1, \dots, x_K) \in \mathbb{R}^{N\times K}$, com energia e regra de atualização

$$E(\xi) = -\operatorname{lse}(\beta, X^\top \xi) + \tfrac{1}{2}\xi^\top \xi + \beta^{-1}\ln K + \tfrac{1}{2}M^2, \qquad M = \max_i \|x_i\|, \tag{2.7}$$

$$\xi^{\text{novo}} = X\,\operatorname{softmax}(\beta X^\top \xi), \tag{2.8}$$

em que $\operatorname{lse}(\beta, z) = \beta^{-1}\ln\sum_i \exp(\beta z_i)$. Os resultados principais do artigo são: a iteração converge globalmente (Teoremas 1 e 2); para padrões aleatórios na esfera, com probabilidade $1-p$ é possível armazenar ao menos $\sqrt{p}\,c^{(N-1)/4}$ padrões (Teorema 3), em que c depende de β, do raio da esfera, da dimensão e de p — o artigo demonstra $c \geq 3{,}1546$ e $c \geq 1{,}3718$ para dois conjuntos de parâmetros, de modo que o limite cresce exponencialmente com N; e a recuperação ocorre tipicamente em uma atualização, com erro exponencialmente pequeno na separação $\Delta_i = x_i^\top x_i - \max_{j\neq i} x_i^\top x_j$ (Teoremas 4 e 5). O parâmetro β controla o tipo de ponto fixo: média global de todos os padrões, estado metaestável (média de um subconjunto de padrões semelhantes) ou recuperação de um único padrão. A regra (2.8) coincide com a atenção do *Transformer*, o que levou os autores a propor camadas Hopfield (`Hopfield`, `HopfieldPooling` e `HopfieldLayer`) [16, 13].

Interpretação (derivação própria). Substituindo $x_i^\top \xi = \frac{1}{2}\|x_i\|^2 + \frac{1}{2}\|\xi\|^2 - \frac{1}{2}\|\xi - x_i\|^2$ em (2.7), o termo $\frac{1}{2}\xi^\top\xi$ se cancela e resulta (Apêndice F)

$$E(\xi) = -\beta^{-1}\ln\sum_{i=1}^{K} e^{\frac{1}{2}\beta\|x_i\|^2} e^{-\frac{1}{2}\beta\|\xi - x_i\|^2} + \beta^{-1}\ln K + \tfrac{1}{2}M^2.$$

Se todos os padrões têm a mesma norma, $E(\xi) = -\beta^{-1} \ln\left[\frac{1}{K}\sum_i e^{-\beta \cdot \frac{1}{2}\|\xi - x_i\|^2}\right]$, um *mínimo suave* (log-média-exp) das meias distâncias quadráticas aos padrões. Ele tende a $\min_i \frac{1}{2}\|\xi - x_i\|^2$ (vizinho mais próximo) quando $\beta \to \infty$ e à média dessas distâncias (cujo mínimo é o centroide) quando $\beta \to 0$. Além disso, $e^{-\beta E(\xi)}$ é, a menos de constante, uma estimativa de densidade por kernel gaussiano com variância $\sigma^2 = 1/\beta$. **Consequência para este trabalho:** um escore de anomalia baseado em $E(\xi)$ é essencialmente um escore de novidade do tipo KDE/k-NN. Não esperamos grande vantagem sobre essas linhas de base; o valor da rede moderna está na recuperação associativa iterativa e na ligação com a atenção.

Tabela 2. Rede de Hopfield clássica e moderna.

Aspecto	Clássica (Hebb/Storkey)	Moderna (Ramsauer et al.)
Estado	$s \in \{-1, +1\}^N$	$\xi \in \mathbb{R}^N$ (contínuo)
Memória	$W \in \mathbb{R}^{N \times N}$: $O(N^2)$ valores, independente de K	$X \in \mathbb{R}^{N \times K}$: $O(NK)$ valores (guarda os padrões)
Energia	$-\frac{1}{2} s^\top W s$	$-\operatorname{lse}(\beta, X^\top \xi) + \frac{1}{2}\xi^\top \xi + \cdots$
Atualização	$s_i \leftarrow \operatorname{sgn}(\sum_j w_{ij} s_j)$, assíncrona	$\xi \leftarrow X \operatorname{softmax}(\beta X^\top \xi)$
Capacidade (padrões aleatórios)	$\approx 0{,}138N$ (Hebb); $\approx N/\sqrt{2 \ln N}$ (Storkey)	exponencial em N (Teorema 3)
Recuperação	iterativa (varreduras)	tipicamente uma atualização (Teorema 4)
Pontos fixos	padrões, −padrões e estados espúrios	um padrão, estados metaestáveis ou média global (via β)
Hiperparâmetros	regra de armazenamento, θ	β
Fontes	[7, 18, 21]	[16, 11, 4]

2.7 A rede de Hopfield como detector de anomalias

Seja $\mathcal{M} = \{\xi^1, \ldots, \xi^K\}$ o conjunto de padrões normais gravados e q uma observação, codificada como estado inicial s^0. A rede atua como *filtro de recuperação*, $s^0 \mapsto s^*$. Esperamos três regimes (Figura 2):

1. q **normal:** s^0 cai na bacia de um protótipo; $s^* \approx \xi^\mu$, $E(s^0)$ é baixa e poucos bits mudam.
2. q **anômalo fora das bacias:** $E(s^0)$ é alta; a dinâmica altera muitos bits ou termina longe de todos os protótipos.
3. q **anômalo capturado por atrator espúrio** (mistura de padrões ou padrão invertido $-\xi^\mu$): s^* tem energia baixa mas não está próximo de nenhum protótipo; só escores que medem a distância a $\mathcal{M}$ o denunciam (Seção 4.5).

O treinamento é *one-class*: usa somente observações predominantemente normais e nenhum rótulo. Os rótulos entram apenas para escolher o limiar de decisão e para avaliar o detector.

3 Descrição do problema e dos dados

3.1 Definição do problema

Considere uma máquina monitorada continuamente. A cada minuto t são coletadas $D = 38$ métricas de utilização e de atividade, que formam o vetor $x_t \in [0, 1]^D$. Especialistas de domínio marcaram os intervalos em que a máquina esteve em incidente, o que fornece o rótulo $y_t \in \{0, 1\}$ (0

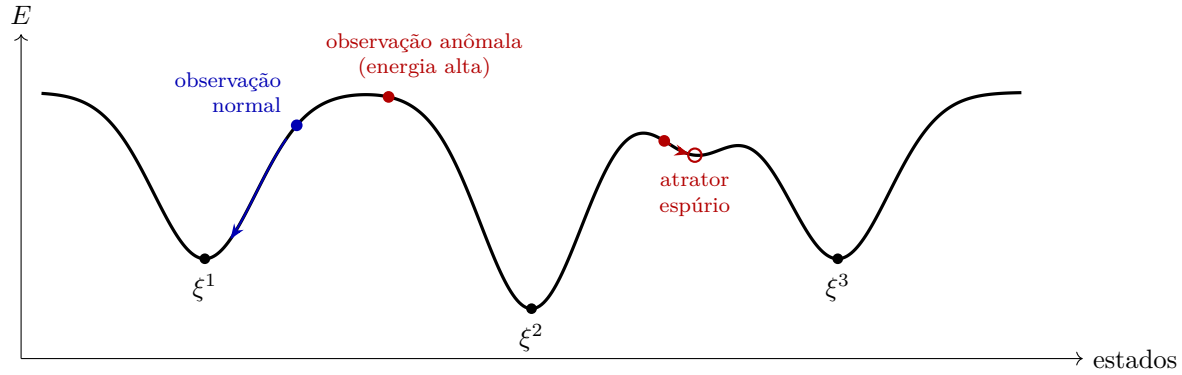


Figura 2. Paisagem de energia esquemática, unidimensional: três protótipos normais, um atrator espúrio e três observações. Ilustração conceitual; os valores são arbitrários e não representam resultados.

= normal, 1 = anômalo). A tarefa é uma *classificação binária por ponto*: dado x_t (opcionalmente com uma janela de observações anteriores), prever y_t por

$$\hat{y}_t = \mathbf{1}\big[\, a(x_t) > \tau \,\big], \tag{3.1}$$

em que $a(\cdot)$ é um *escore de anomalia* (quanto maior, mais anômalo) e τ é um limiar escolhido em dados de validação. A rede de Hopfield produz o escore a (Seção 4.5); as linhas de base produzem $\hat{y}_t$ diretamente ou por um escore equivalente.

- **Entrada (atributos):** $x_t \in [0,1]^{38}$, com 38 métricas numéricas anônimas ("carga de CPU, uso de rede, uso de memória etc." [19]), sem nomes nem unidades, amostradas a cada minuto.
- **Saída desejada:** o rótulo $y_t \in \{0,1\}$ e, no caso do detector, o escore $a(x_t)$.
- **Unidade de modelagem:** cada máquina é tratada separadamente, com seus próprios dados de treino e de teste [19].

3.2 O conjunto de dados SMD

Adotamos o *Server Machine Dataset* (SMD), publicado por Su et al. [19] e disponibilizado no repositório do OmniAnomaly [14]. Ele reúne cerca de cinco semanas de telemetria de 28 máquinas ("entidades") de uma grande empresa de Internet, divididas em três grupos de 8, 9 e 11 máquinas, com 38 métricas por máquina e amostragem de 1 minuto. Para cada máquina, a primeira metade da série é o conjunto de treino (*sem rótulos*) e a segunda é o conjunto de teste, rotulado por especialistas de domínio a partir de relatórios de incidentes [19]. Os dados *não* são redistribuídos neste projeto (Seção 4.12).

Calculamos as estatísticas a seguir diretamente dos arquivos do repositório. Há 708.405 linhas de treino e 708.420 de teste (as duas metades de uma máquina diferem em no máximo uma linha). Dos pontos de teste, 29.444 (4,16 %) são anômalos e se agrupam em 327 segmentos contíguos, com duração média de 90,0 min e extremos de 2 e 3.161 min. Um classificador que responde sempre "normal" acerta 95,84 % dos pontos de teste; portanto a acurácia, isoladamente, é uma métrica inadequada (Seção 4.9). A Tabela 3 resume os três grupos; o Apêndice G traz os números por máquina.

Na máquina 1-1, que usamos como exemplo ao longo do texto, cada metade tem 28.479×38 valores, todos em $[0,1]$, sem valores ausentes e sem linhas de treino duplicadas. A verificação das

Tabela 3. SMD por grupo. Estatísticas calculadas pelos autores sobre os arquivos do repositório. Anôm. = pontos anômalos do teste; Seg. = segmentos anômalos; Prev. = prevalência de anomalias por máquina (mínimo e máximo do grupo).

Grupo	Máquinas	Pontos de teste	Anôm. (%)	Seg.	Prev. por máquina	Linhas de treino
1	8	194.374	11.742 (6,04)	112	0,42–15,65 %	194.369
2	9	223.325	9.703 (4,34)	114	0,68–11,95 %	223.320
3	11	290.721	7.999 (2,75)	101	0,69–4,78 %	290.716
Total	28	708.420	29.444 (4,16)	327	0,42–15,65 %	708.405

demais máquinas faz parte da preparação (Seção 4.2).

3.3 Três exemplos reais

A Tabela 4 mostra três observações reais da máquina `machine-1-1`: uma normal (linha 15.000 do arquivo de teste) e duas anômalas (linhas 16.100 e 17.200, dentro dos segmentos 15.850–16.395 e 16.964–17.517). Por brevidade, mostramos 10 dos 38 atributos — os que o arquivo `interpretation_label` associa a esses segmentos — junto com a mediana, o percentil 95 e o máximo do *treino*. O arquivo `interpretation_label` indica, para cada segmento anômalo, os atributos que o explicam (numerados a partir de 1); seus intervalos diferem ligeiramente dos do arquivo de rótulos (por exemplo, 15.849–16.368 contra 15.850–16.395).

Tabela 4. Três exemplos reais da máquina `machine-1-1` (linhas do arquivo de teste, contadas a partir de 1) e estatísticas dos mesmos atributos no treino. Atributos numerados a partir de 1. Em negrito, valor acima do máximo do treino. O atributo 29 é constante (igual a zero) em todo o treino.

	Teste			Treino		
Atributo	linha 15.000 ($y = 0$)	linha 16.100 ($y = 1$)	linha 17.200 ($y = 1$)	mediana	p95	máximo
1	0,0968	**0,5161**	**0,5161**	0,0430	0,1398	0,4946
2	0,0794	0,0816	0,1250	0,0456	0,1409	0,4216
9	0,0288	0,0129	0,0254	0,0210	0,0355	0,1181
10	0,0000	0,0035	0,0182	0,0000	0,0004	0,1404
12	0,1081	0,2297	0,1351	0,0946	0,1622	0,7432
13	0,0274	0,0548	0,0548	0,0274	0,0548	0,3151
14	0,0575	0,0314	0,0700	0,0500	0,0781	0,1231
15	0,1250	0,0684	0,0965	0,0969	0,1395	0,5650
25	0,0493	0,0313	0,0364	0,0145	0,0561	0,1796
29	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000

No exemplo da linha 16.100, o atributo 1 sobe a 0,5161, acima de todo o treino (máximo 0,4946), e o atributo 12 chega a 0,2297, acima do percentil 95 do treino (0,1622). No exemplo da linha 17.200, o atributo 1 repete o valor 0,5161, mas os demais desvios são pequenos em valor absoluto: o atributo 10 vale 0,0182, muito acima do percentil 95 do treino (0,0004) e ainda assim dentro do intervalo observado (máximo 0,1404). A tarefa já mostra, portanto, uma dificuldade típica: "anômalo" nem sempre significa "fora da faixa". Em toda a máquina 1-1, apenas 18,19 % dos pontos anômalos têm o atributo 1 acima do máximo do treino (contra 0,19 % dos normais) e apenas 1,00 % têm o atributo 10 acima do seu máximo (contra 0,00 % dos normais).

3.4 Exploração dos dados: atributos constantes e deriva

Atributos constantes. Na máquina 1-1, 8 dos 38 atributos são constantes no treino (atributos 5, 8, 17, 18, 27, 29, 37 e 38), restando 30 atributos variáveis. No teste, o atributo 27 deixa de ser constante em 22 linhas (todas anômalas) e o atributo 29 em 225 linhas (211 anômalas e 14 normais). Um atributo que "nunca se mexia" e passa a se mexer é um sinal de novidade que a codificação precisa preservar (Seção 4.3).

Deriva entre treino e teste. Como o teste vem depois do treino, a distribuição dos atributos pode mudar mesmo sem anomalias (*drift*). Para quatro máquinas (1-1, 1-3, 2-5 e 3-6) comparamos, atributo a atributo, a distribuição do treino com a das linhas *normais* do teste pela estatística de Kolmogorov–Smirnov (KS), e contamos as linhas com ao menos um atributo acima do máximo do treino (Tabela 5).

Tabela 5. Deriva entre treino e teste em quatro máquinas (cálculo próprio). KS: estatística de Kolmogorov–Smirnov entre o treino e as linhas normais do teste, sobre os atributos variáveis. "Acima do máx.": percentual de linhas do teste com ao menos um atributo acima do máximo do treino.

Máquina	Atributos variáveis	Atributos com KS $> 0{,}2$	KS mediana	Acima do máx.: normais / anômalas	Atributos constantes no treino
1-1	30	22	0,37	30,1 % / 71,6 %	8 (5, 8, 17, 18, 27, 29, 37, 38)
1-3	34	7	0,08	0,9 % / 18,0 %	4 (8, 27, 37, 38)
2-5	31	2	0,06	1,1 % / 17,2 %	7 (5, 8, 17, 18, 29, 37, 38)
3-6	30	7	0,13	6,5 % / 35,8 %	8 (5, 8, 17, 18, 27, 29, 37, 38)

A deriva é *heterogênea*: forte na máquina 1-1 (22 dos 30 atributos com KS $> 0{,}2$; KS máximo de 0,70 no atributo 30) e leve em 1-3 e 2-5. Na máquina 1-1, o atributo 30 sozinho responde por 26,79 % das linhas normais acima do máximo do treino (atributos 4 e 3: 5,41 % e 3,91 %), e apenas 0,02 % das linhas têm algum atributo abaixo do mínimo do treino. Excluindo esses três atributos, o percentual de linhas acima do máximo cai para 5,4 % nas normais contra 43,5 % nas anômalas. Duas conclusões orientam a metodologia: (i) "acima do máximo do treino" *sozinho* é um detector pobre, pois dispara em muitas linhas normais quando há deriva e deixa passar muitas anomalias quando não há; (ii) a calibração do limiar e, em implantações reais, a atualização periódica do modelo são essenciais.

3.5 Adequação ao tema e limitações do conjunto

Pontos favoráveis. Os dados são reais, de produção, com métricas de utilização e de atividade por máquina; os rótulos vêm de incidentes registrados; e o treino é *sem rótulos*, o que combina com o treinamento *one-class* da rede de Hopfield (Seção 2.7).

Limitações.

- **"Baixo nível" é aproximado.** São 38 contadores anonimizados de utilização de recursos, sem chamadas de sistema nem rastros de *kernel*. O SMD é um substituto para estudar a abordagem; a coleta própria de telemetria (`psutil`, eBPF) com injeção de falhas é trabalho futuro (Seção 7).
- **Atributos anônimos.** Sem nomes ou unidades, não há semântica a explorar na interpretação dos resultados nem como conhecimento prévio de um LLM (Etapa II).

- **Rótulos de incidentes.** As fronteiras dos segmentos são imprecisas (basta ver a diferença entre os arquivos de rótulos e de interpretação) e o rótulo vale para o intervalo inteiro, mesmo que o efeito nas métricas varie dentro dele.
- **Treino sem rótulos.** A metade de treino pode conter anomalias não marcadas; assumimos que é majoritariamente normal.
- **Heterogeneidade.** A prevalência varia de 0,42 % a 15,65 % por máquina, e a deriva também (Tabela 5). Várias máquinas não têm anomalias em algum dos blocos cronológicos usados para treinar, validar e testar (Seção 4.7).
- **Licença.** O repositório do OmniAnomaly declara licença MIT; confirmar os termos de uso dos dados antes de qualquer redistribuição.

4 Metodologia

4.1 Visão geral

A Figura 3 resume a abordagem. Na fase *offline*, a metade de treino (sem rótulos) é limpa, binarizada por uma codificação em termômetro, resumida em K protótipos, e esses protótipos são gravados na matriz de pesos W. Na fase *online*, cada observação é codificada, a rede a leva a um estado estável e a diferença entre o estado inicial e o recuperado (ou a energia) vira um escore de anomalia, que um limiar converte em $\hat{y}_t$. Rótulos só são usados para escolher o limiar e para avaliar (Seção 4.7).

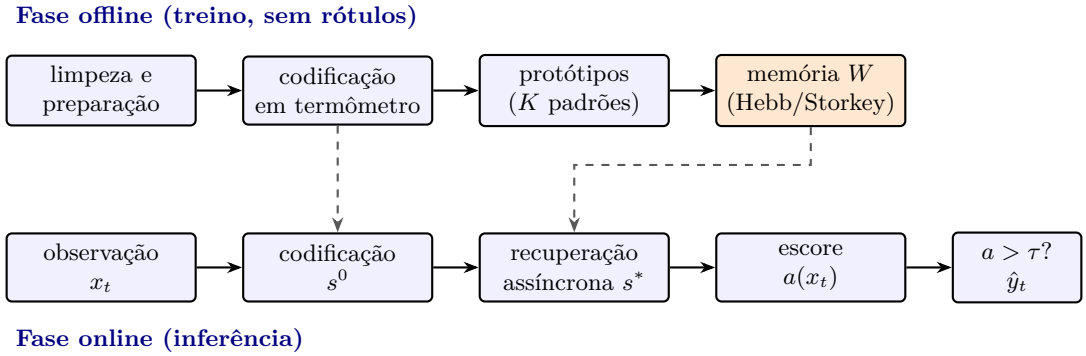


Figura 3. Pipeline do detector. Setas tracejadas: parâmetros aprendidos *offline* (limiares da codificação e matriz de pesos) e reutilizados *online*.

4.2 Preparação e limpeza

1. **Verificação por máquina:** dimensões ($n \times 38$), valores ausentes, valores fora de $[0, 1]$, linhas duplicadas e coerência entre o número de linhas do teste e o do arquivo de rótulos. Na máquina 1-1 não há problemas (Seção 3.2). Se houver valores ausentes em outras máquinas, serão preenchidos com o último valor válido, nunca com estatísticas do teste.
2. **Ordem temporal preservada:** nada é embaralhado.
3. **Sem normalização adicional:** os valores já estão em $[0, 1]$. Os modelos que exigem padronização (SVM, MLP, k-NN, OC-SVM) usam média e desvio-padrão calculados *apenas* no treino; atributos constantes recebem escala 1, de modo que um desvio no teste continue visível.

4. **Atributos constantes** no treino são mantidos e tratados por um bit de novidade (Seção 4.3).

5. **Treino sem remoção de *outliers*:** sem rótulos, não há como identificar com segurança as anomalias eventualmente presentes no treino; a mitigação é a seleção de protótipos com descarte de grupos muito pequenos (Seção 4.4).

6. **Janelas (ablação):** opcionalmente, x_t é ampliado com resumos (média e máximo por atributo) dos últimos w minutos, para capturar a dinâmica temporal. O modelo-base usa só a observação instantânea.

4.3 Codificação binária em termômetro

A rede de Hopfield discreta trabalha com estados em $\{-1,+1\}^N$, enquanto $x_t \in [0,1]^{38}$. Hopfield e Tank [9, p. 145] observam que, numa memória prática, é preciso uma transformação que codifique a informação do mundo real na representação binária da memória. Usamos a codificação em *termômetro*.

Para cada atributo variável j e um número de níveis b, os limiares $\tau_{j,l}$ são os quantis empíricos do treino de ordem $l/(b+1)$, $l = 1,\ldots,b$, descartando repetidos e os que não satisfazem $\min_t x_{t,j} \le \tau < \max_t x_{t,j}$ (assim cada bit varia no treino). O código do atributo é $s_{j,l} = +1$ se $x_j > \tau_{j,l}$ e $s_{j,l} = -1$ caso contrário. Cada atributo *constante* no treino, com valor c_j, recebe um único *bit de novidade*: $+1$ se $|x_j - c_j| > \varepsilon$ ($\varepsilon = 10^{-6}$) e -1 caso contrário. O estado total tem $N = N_{\text{term}} + n_{\text{const}}$ bits.

Uma propriedade útil (derivada no Apêndice F): para um mesmo atributo, a distância de Hamming entre os códigos de dois valores é o número de limiares entre eles, isto é, a diferença de postos (quantis). A distância de Hamming entre estados completos é, portanto, uma distância *ordinal*, somada entre atributos, o que a torna insensível à escala de cada atributo.

Tabela 6. Exploração da codificação em termômetro na máquina 1-1 (metade de treino, 28.479 linhas; cálculo próprio). "Padrões distintos": linhas de treino com códigos diferentes. $\bar{s}_k$: média do bit k no treino. A última coluna é a razão entre o número de linhas de treino e a capacidade clássica $0{,}138N$.

b	Bits de termômetro	N (com 8 de novidade)	Padrões distintos	Média dos bits	Média de $\lvert\bar{s}_k\rvert$	Treino / $(0{,}138N)$
2	59	67	22.855	−0,065	0,333	3.080
4	114	122	27.670	−0,064	0,405	1.692
8	216	224	28.459	−0,040	0,451	921
16	404	412	28.479	−0,032	0,480	501

A Tabela 6 traz dois alertas. Primeiro, o número de linhas de treino é de 501 a 3.080 vezes a capacidade clássica: *armazenar todos os pontos é impossível*, e precisamos de $K \ll 0{,}138N$ protótipos (ou da rede moderna, com memória grande). Segundo, os bits do termômetro são *viesados por construção*: o bit do quantil $l/(b+1)$ tem média $1 - 2l/(b+1)$ no treino, e a média de $|\bar{s}_k|$ fica entre 0,33 e 0,48. As estimativas de capacidade da Seção 2.4 supõem padrões não viesados, logo a capacidade efetiva deve ser menor que a da Tabela 1. Por fim, cada bit de novidade pesa apenas $1/N$ em S_1 (Seção 4.5), um sinal fraco; combinar o detector com uma regra explícita é uma extensão possível (Seção 7).

4.4 Memória de protótipos

Os K padrões armazenados são escolhidos entre os códigos da metade de treino por *k-medoids* no espaço de Hamming (ou *k-modes*), ajustado sobre uma subamostra de até 5.000 pontos para limitar o custo. Usar medoides garante que cada protótipo seja um padrão realmente observado. Grupos com menos de uma pequena fração dos pontos (por exemplo, 1 %) podem ser descartados, para diminuir o risco de gravar anomalias que estejam no treino. Variamos $K \in \{2, 5, 10, 20, 30\}$; esse intervalo inclui valores acima da capacidade teórica (por exemplo, $K = 30$ com $N = 67$, $K/N \approx 0{,}45$) de propósito, para observar a degradação prevista (H1, Seção 4.10). Os protótipos são gravados com a regra de Hebb (2.3) ou de Storkey (2.4), com $\theta = 0$ (Algoritmo 1).

4.5 Recuperação e escores de anomalia

Dada uma observação x_t, o detector (i) calcula $s^0 = \mathrm{cod}(x_t)$; (ii) executa a recuperação assíncrona (Algoritmo 2): varreduras em ordem aleatória até que uma varredura completa não altere nenhum bit, com no máximo $T_{\max} = 100$ varreduras — a Proposição 2.2 garante a parada — e obtém s^*; (iii) calcula os escores da Tabela 7.

Tabela 7. Escores de anomalia da rede clássica (quanto maior, mais anômalo). ξ^μ: protótipos armazenados; E: energia (2.2). Propostas de projeto.

Escore	Definição	Leitura
S_1	$d_{\mathrm{H}}(s^0, s^*)/N$	fração dos bits alterada pela dinâmica
S_2	$\min_\mu d_{\mathrm{H}}(s^0, \xi^\mu)/N$	distância ao protótipo mais próximo *sem* dinâmica (referência do vizinho mais próximo no espaço do código)
S_3	$E(s^0)$	energia do estado inicial
S_4	$E(s^0) - E(s^*)$	energia liberada pela recuperação
S_5	$\min_\mu d_{\mathrm{H}}(s^*, \xi^\mu)/N$	distância do estado final ao protótipo mais próximo (alta ⇒ estado espúrio ou invertido)
S_6	nº de varreduras com ao menos uma troca	tempo de convergência

A comparação entre S_1 e S_2 mede se a dinâmica recorrente acrescenta algo à simples busca do protótipo mais próximo (ablação). Usamos a distância *com sinal*, e não o módulo da sobreposição, de modo que o padrão invertido $-\xi^\mu$ — que é ponto fixo com a mesma energia de ξ^μ quando $\theta = 0$ (Seção 2.4) — conte como distante: para uma consulta igual a $-\xi^\mu$, $S_1 = 0$ e S_3 é baixo, mas $S_2 = S_5 = 1$ (Apêndice B).

Variante moderna. A memória é a matriz X formada pelas linhas de treino (ou por uma subamostra ou centroides de k-means), no espaço contínuo — atributos em $[0, 1]$ ou padronizados, sem normalizar cada vetor, porque a magnitude carrega informação. Com $\beta \in \{1, 10, 100, 1000\}$ (ou seja, $\sigma = \beta^{-1/2}$), os escores são $E(\xi^0)$ (Eq. 2.7), o resíduo de recuperação $\|\xi^0 - X\,\mathrm{softmax}(\beta X^\top \xi^0)\|$ e a entropia do vetor $\mathrm{softmax}(\beta X^\top \xi^0)$ (Algoritmo 4). O custo por consulta é $O(NK)$ com $N = 38$ e K até o número de linhas de treino. Pela Seção 2.6, esperamos que esses escores se comportem como escores de densidade por kernel.

4.6 Linhas de base

O enunciado exige ao menos dois modelos de classificação da lista (*Decision Trees*, *Random Forest*, *Naive Bayes*, SVM, MLP, XGBoost e KNN) [20]. Como a rede de Hopfield não consta da lista

(Seção 1), tratamo-la como *modelo do tema* e usamos as linhas de base abaixo, implementadas com o `scikit-learn` [15].

- **Supervisionadas (Etapa I):** *Random Forest* (com `class_weight='balanced'`) e SVM com núcleo RBF, treinadas em L_{tr} (Seção 4.7) sobre os 38 atributos originais. São uma *referência superior*: usam rótulos, ao contrário do detector *one-class*, e portanto a comparação com o Hopfield não é de igual para igual.
- ***One-class* (comparação justa):** *One-Class SVM* e distância ao k-ésimo vizinho mais próximo (k-NN), ajustados apenas na metade de treino sem rótulos, como a rede de Hopfield.
- **Opcional:** MLP (classificador ou autoencoder).

4.7 Divisão dos dados e protocolos de avaliação

A metade de treino do SMD não tem rótulos; rótulos — para treinar modelos supervisionados, escolher limiares e avaliar — só existem na metade de teste. Dividimos essa metade *cronologicamente* em três blocos, nunca por sorteio: pontos vizinhos de uma série temporal são fortemente correlacionados e um sorteio vazaria informação do teste para o treino. Seja n o número de linhas da metade rotulada, $c_1 = \text{round}(0{,}4\,n)$ e $c_2 = \text{round}(0{,}6\,n)$:

$$L_{\text{tr}} = [0,\, c_1 - 60), \qquad L_{\text{val}} = [c_1 + 60,\, c_2 - 60), \qquad L_{\text{te}} = [c_2 + 60,\, n), \tag{4.1}$$

com um *embargo* de 60 amostras (1 hora) de cada lado de cada corte, para que nenhuma informação vaze entre blocos vizinhos. Cada corte é deslocado, se necessário, para a zona mais próxima sem anomalias em ±60 amostras, de modo que nenhum segmento anômalo atravesse uma fronteira nem caia no embargo. Dos 56 cortes (28 máquinas × 2), apenas 5 foram deslocados: c_1 nas máquinas 2-4 (9.413 em vez de 9.476) e 3-7 (11.431 em vez de 11.482), e c_2 nas máquinas 1-1 (16.903 em vez de 17.087), 2-9 (17.346 em vez de 17.233) e 3-8 (17.336 em vez de 17.222). A metade de treino (sem rótulos) também é dividida em ordem cronológica: S_{aj} (primeiros 80 %), onde se ajustam os modelos *one-class*, e S_{cal} (últimos 20 %), usada para calibrar o limiar sem rótulos.

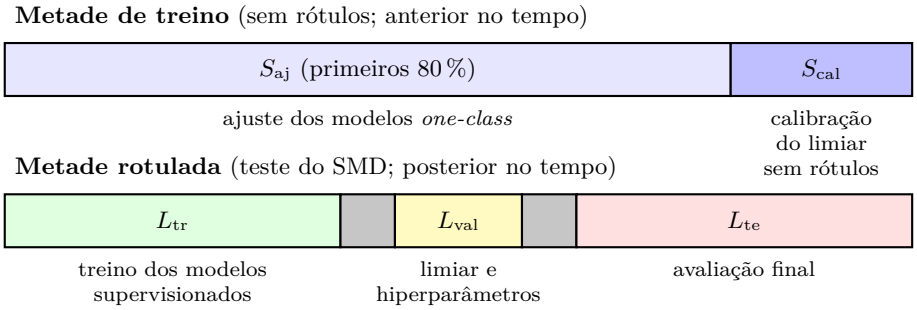


Figura 4. Divisão cronológica de uma máquina (esquema fora de escala). As faixas cinza são os embargos de 60 amostras, centrados nos cortes c_1 e c_2.

Elegibilidade das máquinas. Nem toda máquina tem anomalias em todos os blocos (Tabela 8; números por máquina no Apêndice G). Para treinar um classificador supervisionado é preciso ter as duas classes em L_{tr}; para escolher o limiar, anomalias em L_{val}. Por isso o Protocolo S, descrito abaixo, usa 18 máquinas (e 23 para os modelos *one-class*), e as 5 restantes entram apenas no

Protocolo U. Alguns L_{val} têm pouquíssimas anomalias (máquina 3-5: 3; 2-2: 11; 3-3: 15; 1-8: 16; 3-4: 20; 1-6: 27), de modo que o limiar não é ajustado por máquina, e sim globalmente, sobre o L_{val} agregado.

Tabela 8. Elegibilidade das máquinas, conforme a existência de anomalias em cada bloco (cálculo próprio).

Classe	Anomalias em L_{tr} / L_{val} / L_{te}	Máquinas	Uso
S (18)	> 0 / > 0 / > 0	1-3, 1-4, 1-6, 1-7, 1-8, 2-1, 2-3, 2-4, 2-5, 2-6, 2-7, 3-2, 3-3, 3-4, 3-5, 3-6, 3-7, 3-10	Protocolo S (supervisionados e *one-class*)
O (5)	0 / > 0 / > 0	1-1, 1-5, 2-2, 2-9, 3-8	Protocolo S, só *one-class*
– (5)	$L_{\text{val}} = 0$	1-2, 2-8, 3-1, 3-9, 3-11	só Protocolo U

Tabela 9. Blocos cronológicos agregados (soma das máquinas de cada conjunto; cálculo próprio).

Conjunto	Bloco	Linhas	Anômalas	Prevalência
18 máquinas (S)	L_{tr}	175.448	6.664	3,80 %
	L_{val}	86.273	1.970	2,28 %
	L_{te}	175.562	10.545	6,01 %
23 máquinas (S+O)	L_{tr}	228.473	6.664	2,92 %
	L_{val}	112.377	4.500	4,00 %
	L_{te}	228.544	16.768	7,34 %

A prevalência muda de bloco para bloco (de 2,28 % a 6,01 % nas 18 máquinas), de modo que um limiar ótimo em L_{val} não é necessariamente ótimo em L_{te}; esse é um dos motivos para reportar também métricas independentes de limiar (AUC-ROC e PR-AUC). Para análises detalhadas e para a Etapa II escolhemos uma máquina representativa por grupo, todas com anomalias em todos os blocos: **1-3**, **2-5** e **3-6** (anomalias em $L_{\text{tr}}/L_{\text{val}}/L_{\text{te}}$: 86/281/450, 314/39/627 e 174/437/583; prevalências de 3,45 %, 4,14 % e 4,16 %, próximas dos 4,16 % do conjunto).

Limiar de decisão. Escores de máquinas diferentes não são diretamente comparáveis. Para os modelos *one-class*, o limiar de cada máquina é o quantil $(1 - \alpha)$ dos escores em S_{cal} — isto é, α é a taxa de alarmes tolerada sobre o comportamento normal — e α é um parâmetro *global*. Para os modelos supervisionados, o parâmetro global é o limiar sobre a probabilidade prevista.

Tabela 10. Protocolos de avaliação (propostas de projeto).

	Protocolo S (principal)	Protocolo U (secundário, sem rótulos)
Máquinas	18 (classe S); modelos *one-class* também nas 5 da classe O	28
Ajuste	*one-class*: S_{aj}; supervisionados: L_{tr}	*one-class*: S_{aj}
Limiar e hiperparâmetros	globais, escolhidos por F_1 em L_{val} agregado (α ou limiar de probabilidade)	$\alpha \in \{0{,}5;\ 1;\ 2;\ 5\}$ % fixado *a priori*; limiar por máquina em S_{cal}
Avaliação	L_{te}	toda a metade rotulada
Relato	todas as métricas da Seção 4.9	AUC-ROC, PR-AUC e métricas no limiar sem rótulos; F_1 ótimo ("oráculo") só como teto otimista

Agregação e significância. Reportamos a média entre máquinas (*macro*) e as contagens agregadas (*micro*); a AUC-ROC e a PR-AUC são calculadas por máquina e promediadas. Comparações entre modelos usam o teste de Wilcoxon dos postos sinalizados, pareado por máquina, e as partes estocásticas (ordem de atualização, inicialização do *k-medoids*, *Random Forest*, MLP) são repetidas com 3 sementes.

4.8 Balanceamento de classes

Com 4,16 % de pontos anômalos, o desbalanceamento é forte, mas seu tratamento depende do modelo:

- o detector *one-class* (Hopfield, OC-SVM, k-NN) não usa rótulos no ajuste, logo não há o que balancear;
- nos modelos supervisionados usamos pesos de classe (`class_weight='balanced'`) ou subamostragem da classe majoritária, *apenas em* L_{tr};
- não usamos SMOTE nem sobreamostragem sintética: elas criam observações que nunca ocorreram e ignoram a dependência temporal;
- L_{val} e L_{te} mantêm a prevalência natural e nunca são balanceados (a única exceção, a subamostra da Etapa II, é corrigida por prevalência; Seção 4.9).

4.9 Métricas de avaliação

Com a classe anômala como positiva e TP, FP, FN, TN as contagens ponto a ponto,

$$\text{acurácia} = \frac{TP+TN}{TP+TN+FP+FN}, \qquad P = \frac{TP}{TP+FP}, \qquad R = \frac{TP}{TP+FN},$$
$$F_\gamma = (1+\gamma^2)\frac{P\,R}{\gamma^2 P + R}, \qquad \text{FPR} = \frac{FP}{FP+TN},$$

$$\text{MCC} = \frac{TP\cdot TN - FP\cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}.$$

Reportamos as métricas mínimas do enunciado: acurácia, precisão (P), revocação (R, *recall*), F_1 e F_2 ($\gamma = 1$ e $\gamma = 2$; este pesa mais a revocação), AUC-ROC [5] e matriz de confusão. Como complemento, a PR-AUC (preferível à AUC-ROC com classes desbalanceadas [17]), o MCC, o tempo de inferência por 100 amostras e o custo de memória ($O(N^2)$ na rede clássica). O limiar é escolhido maximizando F_1 em L_{val} agregado; F_2 é reportado no mesmo limiar.

Avaliação por ponto e por segmento. A avaliação principal é *por ponto*. Na avaliação por segmento (*point-adjust*), basta acertar um ponto de um segmento anômalo para que o segmento inteiro conte como acerto, o que infla as métricas [10]; ela é a usada em parte da literatura do SMD [19] e a reportamos apenas como secundária, para comparação.

Precisão ajustada à prevalência. Se um conjunto for subamostrado com prevalência diferente da natural π (caso da Etapa II), a precisão passa a ser $P_{\text{nat}} = \dfrac{R\,\pi}{R\,\pi + \text{FPR}\,(1-\pi)}$, pois R e FPR não dependem da prevalência.

4.10 Experimentos e hipóteses

E1a — capacidade em padrões sintéticos. Para $N \in \{67, 122, 224, 412\}$, armazenar K padrões aleatórios não viesados (Hebb e Storkey) e medir a fração de padrões que são pontos fixos e a taxa de recuperação a partir de versões ruidosas (inversão de uma fração dos bits) em função de K/N, comparando com a Tabela 1. Valida a implementação.

E1b — capacidade com protótipos do SMD. A mesma análise com os protótipos codificados do SMD, para ver o efeito de bits viesados e correlacionados.

E2 — detecção de anomalias. Protocolos S e U (Seção 4.7), com os modelos da Seção 4.6.

E3 — Etapa II. Protocolo da Seção 4.11.

E4 (opcional) — interpretabilidade. Comparar os atributos cujos bits foram alterados na recuperação com os atributos indicados em `interpretation_label`.

As **ablações** cobrem: número de níveis $b \in \{2, 4, 8, 16\}$; número de protótipos $K \in \{2, 5, 10, 20, 30\}$; regra (Hebb ou Storkey); dinâmica recorrente (S_1 *versus* S_2); janelas temporais; $\beta \in \{1, 10, 100, 1000\}$ na variante moderna; e, de forma exploratória e fora da bibliografia fornecida, uma regra de Hebb *centrada* para bits viesados.

Hipóteses (expectativas *a priori*, não resultados).

H1 Com a regra de Hebb, a recuperação se degrada quando K/N passa de cerca de 0,1.

H2 A regra de Storkey é ao menos tão boa quanto a de Hebb com protótipos correlacionados.

H3 A rede moderna, com β adequado, detecta melhor que a clássica.

H4 No Protocolo S, *Random Forest* e SVM superam o Hopfield *one-class*; no Protocolo U, o Hopfield é competitivo com OC-SVM e k-NN.

H5 O LLM em *zero-shot* é fraco em telemetria numérica anônima; o *few-shot* melhora, mas não supera o *Random Forest*.

4.11 Etapa II: LLM *versus* modelos clássicos

A Etapa II compara um modelo de linguagem usado por *prompting* com os modelos clássicos da Etapa I, sobre *os mesmos dados*.

- **Tarefa:** dada uma observação (as 38 métricas anônimas em $[0, 1]$, serializadas como texto), responder em JSON o rótulo (0 ou 1) e um escore de anomalia em $[0, 1]$. Temperatura 0. Registrar o modelo, a versão e a data de execução.
- **Configurações:** *zero-shot* e *few-shot* com $k \in \{3, 5, 10, 20\}$ exemplos de L_{tr}, aproximadamente balanceados (2N+1A, 3N+2A, 5N+5A, 10N+10A, em que N = normal e A = anômalo), sorteados com 3 sementes.
- **Dados:** uma subamostra de L_{te} (500 a 2.000 pontos, conforme o custo) nas máquinas representativas 1-3, 2-5 e 3-6. Os modelos da Etapa I são reavaliados nessa mesma subamostra, com a precisão ajustada por prevalência.
- **Métricas:** as da Etapa I (Seção 4.9), mais o tempo por 100 amostras e o custo estimado de API por 100 amostras (preço por *token* $\times$ *tokens* do *prompt* e da resposta; preços a preencher).

- ***Prompt*:** Apêndice C. Variante opcional: *zero-shot* com um perfil de referência (mediana e percentil 95 de cada métrica no treino normal).

Limitações esperadas: as métricas são anônimas, de modo que o LLM não tem conhecimento prévio sobre o significado de cada uma; o escore autodeclarado do LLM não é calibrado; o resultado é sensível ao formato e à ordem dos exemplos; há custo e latência; e a reprodutibilidade é limitada pela atualização dos modelos. Esta versão do relatório define o protocolo; a execução depende de acesso a um modelo de linguagem (Seção 5).

4.12 Reprodutibilidade

- **Dados:** obtidos do repositório do OmniAnomaly [14], pasta `ServerMachineDataset`, com os subdiretórios `train`, `test`, `test_label` e `interpretation_label` e um arquivo `machine-G-I.txt` por máquina (CSV sem cabeçalho, 38 colunas; um rótulo por linha). Registrar o *commit* usado.
- **Ambiente:** Python 3, NumPy e `scikit-learn` [15]; registrar as versões.
- **Sementes:** 3 por experimento estocástico, fixadas e registradas.
- **Registros:** salvar os escores por máquina e por ponto, para recalcular as métricas sem reexecutar os modelos; medir os tempos sempre na mesma máquina.
- **Código:** os *scripts* dos experimentos não fazem parte desta versão do relatório.

5 Resultados

Estado desta seção

Esta versão do relatório **não contém resultados de modelos**. As tabelas abaixo fixam o formato de relato; as células marcadas com ··· serão preenchidas após os experimentos — nenhum valor foi estimado ou inventado. As estatísticas já obtidas, que são reais, estão nas Tabelas 3, 4, 5, 6, 8 e 9 e no Apêndice G.

5.1 E1: capacidade e recuperação

A Tabela 11 reúne a validação da implementação em padrões sintéticos (E1a). O experimento E1b usa o mesmo formato com os protótipos do SMD, para $K \in \{2, 5, 10, 20, 30\}$ e $b \in \{2, 4, 8, 16\}$. Esperamos que a fração de pontos fixos caia perto de $K/N \approx 0{,}14$ para a regra de Hebb (Tabela 1).

Tabela 11. E1a — fração de padrões aleatórios, não viesados, que são pontos fixos (%), por N, razão K/N e regra de armazenamento (H = Hebb; S = Storkey). A preencher.

	$N = 67$		$N = 122$		$N = 224$		$N = 412$	
K/N	H	S	H	S	H	S	H	S
0,05	···	···	···	···	···	···	···	···
0,10	···	···	···	···	···	···	···	···
0,138	···	···	···	···	···	···	···	···
0,20	···	···	···	···	···	···	···	···
0,30	···	···	···	···	···	···	···	···

5.2 E2: detecção de anomalias

Protocolo S. A Tabela 12 apresenta as métricas médias entre as 18 máquinas da classe S em L_{te} (macro; a AUC-ROC e a PR-AUC são calculadas por máquina e promediadas), e a Tabela 13 as matrizes de confusão agregadas (micro). Os modelos supervisionados são uma referência superior (Seção 4.6).

Tabela 12. Protocolo S — métricas médias entre máquinas em L_{te} (macro). Limiar escolhido por F_1 em L_{val} agregado. Tempo: inferência por 100 amostras. A preencher.

Modelo	Acur.	P	R	F_1	F_2	AUC-ROC	PR-AUC	MCC	s/100
Hopfield clássico (Hebb)	···	···	···	···	···	···	···	···	···
Hopfield clássico (Storkey)	···	···	···	···	···	···	···	···	···
Hopfield moderno	···	···	···	···	···	···	···	···	···
OC-SVM	···	···	···	···	···	···	···	···	···
k-NN (dist. ao k-ésimo vizinho)	···	···	···	···	···	···	···	···	···
Random Forest (supervisionado)	···	···	···	···	···	···	···	···	···
SVM-RBF (supervisionado)	···	···	···	···	···	···	···	···	···

Tabela 13. Protocolo S — matrizes de confusão agregadas (micro) em L_{te} (positivo = anômalo). A preencher.

Modelo	TP	FP	FN	TN
Hopfield clássico (melhor configuração)	···	···	···	···
Hopfield moderno	···	···	···	···
OC-SVM	···	···	···	···
k-NN	···	···	···	···
Random Forest	···	···	···	···
SVM-RBF	···	···	···	···

Protocolo U. A Tabela 14 traz os modelos *one-class* avaliados nas 28 máquinas, com limiar sem rótulos definido por α. A AUC-ROC e a PR-AUC independem de α.

5.3 Ablações do detector de Hopfield

A Tabela 15 mostra o efeito do número de níveis b, do número de protótipos K e da regra de armazenamento sobre a PR-AUC média (Protocolo S, escore S_1), e a Tabela 16 compara os escores da Tabela 7.

5.4 E3: Etapa II — LLM *versus* modelos clássicos

A Tabela 17 segue o protocolo da Seção 4.11. Os modelos clássicos são reavaliados na *mesma* subamostra.

5.5 E4 (opcional): interpretabilidade

Quando realizado, comparará os atributos cujos bits foram alterados na recuperação com os atributos de `interpretation_label`: **[a preencher]**.

Tabela 14. Protocolo U — 28 máquinas, toda a metade rotulada, limiar sem rótulos (quantil $1-\alpha$ em S_{cal}). F_1^*: F_1 ótimo com acesso aos rótulos (teto otimista, não comparável). A preencher.

Modelo	α	Acur.	P	R	F_1	AUC-ROC	PR-AUC	F_1^*
Hopfield clássico	0,5 %	···	···	···	···	···	···	···
	1 %	···	···	···	···			
	2 %	···	···	···	···			
	5 %	···	···	···	···			
Hopfield moderno	0,5 %	···	···	···	···	···	···	···
	1 %	···	···	···	···			
	2 %	···	···	···	···			
	5 %	···	···	···	···			
OC-SVM	0,5 %	···	···	···	···	···	···	···
	1 %	···	···	···	···			
	2 %	···	···	···	···			
	5 %	···	···	···	···			
k-NN	0,5 %	···	···	···	···	···	···	···
	1 %	···	···	···	···			
	2 %	···	···	···	···			
	5 %	···	···	···	···			

Tabela 15. Ablação — PR-AUC média (macro) do detector clássico, escore S_1, Protocolo S, por b, K e regra. A preencher.

Regra	b	$K=2$	$K=5$	$K=10$	$K=20$	$K=30$
Hebb	2	···	···	···	···	···
	4	···	···	···	···	···
	8	···	···	···	···	···
	16	···	···	···	···	···
Storkey	2	···	···	···	···	···
	4	···	···	···	···	···
	8	···	···	···	···	···
	16	···	···	···	···	···

Tabela 16. Comparação dos escores S_1–S_6 na melhor configuração do detector clássico (Protocolo S, macro). A preencher.

Escore	AUC-ROC	PR-AUC
S_1	···	···
S_2	···	···
S_3	···	···
S_4	···	···
S_5	···	···
S_6	···	···

Tabela 17. Etapa II — LLM (modelo, versão e data: **[a preencher]**) e modelos clássicos na mesma subamostra de L_{te} (máquinas 1-3, 2-5 e 3-6; $n =$ **[a preencher]**). Precisão ajustada por prevalência. Custo: estimativa de API por 100 amostras (preços **[a preencher]**). A preencher.

Configuração	Acur.	P_{nat}	R	F_1	F_2	AUC-ROC	s/100	Custo/100
LLM, *zero-shot*	···	···	···	···	···	···	···	···
LLM, *few-shot* $k = 3$	···	···	···	···	···	···	···	···
LLM, *few-shot* $k = 5$	···	···	···	···	···	···	···	···
LLM, *few-shot* $k = 10$	···	···	···	···	···	···	···	···
LLM, *few-shot* $k = 20$	···	···	···	···	···	···	···	···
Random Forest	···	···	···	···	···	···	···	—
SVM-RBF	···	···	···	···	···	···	···	—
Hopfield clássico	···	···	···	···	···	···	···	—
OC-SVM	···	···	···	···	···	···	···	—

6 Comparação crítica

Esta seção organiza a análise crítica em dois eixos: as hipóteses formuladas *antes* dos experimentos (Seção 4.10), com a evidência necessária para aceitá-las ou rejeitá-las, e os pontos positivos e negativos da abordagem, separando o que decorre da teoria e dos dados já examinados do que só os experimentos podem mostrar.

6.1 Hipóteses e evidência necessária

Tabela 18. Hipóteses, evidência necessária e resultado empírico (a preencher após os experimentos).

	Hipótese (resumo)	Evidência necessária	Resultado	Veredito
H1	Hebb degrada com $K/N \gtrsim 0{,}1$	E1a e E1b (Tabela 11)	···	···
H2	Storkey $\geq$ Hebb com protótipos correlacionados	E1a, E1b e ablação (Tabela 15)	···	···
H3	Moderna $>$ clássica	Protocolos S e U (Tabelas 12 e 14); teste de Wilcoxon	···	···
H4	S: supervisionados $>$ Hopfield; U: Hopfield $\approx$ OC-SVM e k-NN	Tabelas 12 e 14; teste de Wilcoxon	···	···
H5	LLM *zero-shot* fraco; *few-shot* melhora, mas não supera o *Random Forest*	Etapa II (Tabela 17)	···	···

Critérios definidos antes dos experimentos (proposta).

- A PR-AUC de um detector aleatório é aproximadamente a prevalência (cerca de 4,16 % no conjunto); um detector só é considerado informativo se superar esse patamar de forma consistente entre as máquinas.
- O detector de Hopfield é considerado *competitivo* se, no Protocolo U, sua PR-AUC média não for significativamente inferior à do melhor entre OC-SVM e k-NN (Wilcoxon pareado por máquina, nível de 5 %).
- Diferenças entre configurações só são destacadas quando maiores que a variação entre as 3 sementes.

6.2 Pontos positivos e negativos

A Tabela 19 lista, por aspecto, o que a teoria e os dados já examinados permitem esperar; a última coluna é reservada às evidências dos experimentos.

Tabela 19. Pontos positivos e negativos esperados (*a priori*) e evidência empírica (a preencher).

Aspecto	Positivo (*a priori*)	Negativo (*a priori*)	Evidência empírica
Treinamento	Regras locais e incrementais (Hebb, Storkey): um novo padrão é somado sem revisitar os anteriores [21]. Treino *one-class*, sem rótulos, compatível com a metade de treino do SMD.	O treino não rotulado pode conter anomalias, que viram protótipos "normais" (contaminação).	···
Capacidade	Para padrões aleatórios, a rede moderna tem capacidade exponencial [16].	A rede clássica guarda $\approx 0{,}138N$ padrões [6]; bits do termômetro viesados reduzem a capacidade efetiva (Tabela 6); poucos protótipos podem não cobrir um comportamento normal multimodal.	···
Estados espúrios	O escore S_2 (distância ao protótipo mais próximo) detecta o padrão invertido $-\xi$ (Apêndice B).	Mínimos espúrios, em número exponencial [2, 16], podem capturar uma observação anômala e mascará-la.	···
Representação	A codificação em termômetro preserva a ordem dos valores e dá uma distância de Hamming ordinal (Apêndice F).	A binarização perde informação e multiplica a dimensão: N de 67 a 412 para 38 atributos.	···
Tempo e deriva	Inferência rápida e com memória fixa: $O(N^2)$ valores na rede clássica.	Sem modelagem temporal (a menos de janelas); sensível à deriva entre treino e teste, que é heterogênea (Tabela 5); exige recalibração do limiar.	···
Custo computacional	Rede clássica: poucas operações por varredura.	A rede moderna guarda os K padrões, com custo $O(NK)$ por consulta e $O(NK)$ de memória.	···
Interpretabilidade	Os bits alterados na recuperação apontam atributos suspeitos (E4).	Atributos anônimos: sem significado para o operador.	···
Rede moderna	Recuperação em uma atualização; ligação com a atenção do *Transformer* [16].	A energia equivale a um escore de densidade por kernel (Seção 2.6): pouca vantagem esperada sobre k-NN e KDE.	···

continua na próxima página

Aspecto	Positivo (*a priori*)	Negativo (*a priori*)	Evidência empírica
Adoção	Base teórica clara (energia, convergência).	A rede clássica é raramente usada em aprendizado de máquina moderno [21]; não consta da lista de modelos do enunciado.	···

6.3 Síntese a priori

Se as hipóteses se confirmarem, o quadro esperado é: o Hopfield *one-class* é útil onde rótulos são escassos ou inexistentes e a latência importa, mas não deve superar um classificador supervisionado quando há rótulos (H4); a variante moderna deve dar ganho sobre a clássica, porém semelhante ao de métodos de densidade (H3); e o LLM sem conhecimento prévio sobre métricas anônimas deve ficar abaixo dos modelos treinados (H5). Essas expectativas são *hipóteses*: a Seção 7 indica como serão revisadas diante dos resultados.

7 Conclusões

7.1 O que já pode ser afirmado

O texto desta versão sustenta as afirmações abaixo, baseadas na teoria e na exploração dos dados; nenhuma delas depende de resultados de modelos.

- A rede de Hopfield discreta é uma memória associativa cuja dinâmica assíncrona não aumenta a energia e termina em um ponto fixo (Proposição 2.2); isso a torna um filtro de recuperação bem definido, mas com capacidade limitada ($\approx 0{,}138N$) e estados espúrios, entre eles o padrão invertido $-\xi$ (Seção 2.4).
- Formulamos um detector *one-class* sobre essa rede, com escores baseados em distância de Hamming e em energia (Seção 4.5). Mostramos, por derivação própria, que o escore de energia da rede moderna é um mínimo suave de distâncias, equivalente a uma densidade por kernel (Seção 2.6); por isso não esperamos vantagem automática sobre k-NN ou KDE.
- No SMD, apenas 4,16 % dos pontos de teste são anômalos; um classificador que sempre responde "normal" acerta 95,84 %, o que torna a acurácia, isoladamente, uma métrica inadequada (Seção 3.2).
- Os dados têm atributos constantes no treino que passam a variar em anomalias, deriva heterogênea entre treino e teste e muitas anomalias sutis, dentro da faixa do treino; "acima do máximo" sozinho é um detector pobre (Seção 3.4).
- A codificação em termômetro produz de 67 a 412 bits e bits viesados; armazenar todos os pontos de treino é inviável (de 501 a 3.080 vezes a capacidade clássica), o que exige poucos protótipos (Seção 4.3).
- Só 18 das 28 máquinas permitem um protocolo supervisionado completo (23 para modelos *one-class*); o Protocolo U cobre as 28 (Seção 4.7).

7.2 O que depende dos experimentos

Dependem de execução: se o detector de Hopfield separa pontos normais de anômalos acima do acaso e de métodos *one-class* simples; o efeito de b, K e da regra de armazenamento; se

a dinâmica recorrente acrescenta algo à busca do protótipo mais próximo; se a rede moderna supera a clássica; e o comportamento do LLM na Etapa II. As hipóteses H1–H5 e os critérios de decisão estão na Seção 6; os resultados serão registrados na Seção 5.

7.3 Limitações

- **Representação:** a binarização perde informação; bits correlacionados e viesados reduzem a capacidade efetiva; poucos protótipos podem não cobrir um comportamento normal multimodal.
- **Modelo:** estados espúrios podem mascarar anomalias; a memória da rede clássica cresce com N^2; não há modelagem temporal, a menos de janelas; a rede é sensível a hiperparâmetros e ao limiar.
- **Dados:** atributos anônimos e de "baixo nível" apenas aproximado; rótulos de incidentes com fronteiras imprecisas; treino sem rótulos e possivelmente contaminado; deriva entre treino e teste; grande variação entre máquinas.
- **Escopo:** esta versão não traz resultados experimentais nem a execução da Etapa II, e o Hopfield não consta da lista de modelos do enunciado (a confirmar com o professor).

7.4 Próximos passos

1. Confirmar com o professor o uso da rede de Hopfield como modelo do tema, com *Random Forest* e SVM como linhas de base da Etapa I.
2. Implementar o *pipeline* (codificação, protótipos, Hebb e Storkey, recuperação, escores) e validá-lo com E1a (Tabela 11).
3. Executar E1b, E2 (Protocolos S e U), as ablações e as linhas de base, e preencher a Seção 5.
4. Executar a Etapa II com um modelo de linguagem, registrando modelo, versão, tempo e custo.
5. Revisar a Seção 6 e estas conclusões à luz dos resultados.
6. Preparar a apresentação remota (cronograma proposto no Apêndice D).

Trabalhos futuros. (i) Combinar o detector com uma regra explícita para atributos que saem de um valor constante, já que o bit de novidade tem peso apenas $1/N$; (ii) testar uma regra de Hebb centrada para bits viesados; (iii) usar a rede moderna com memória grande e janelas temporais; (iv) coletar telemetria própria em baixo nível (por exemplo, com `psutil` ou eBPF) e injetar falhas controladas (por exemplo, com `stress-ng`); (v) reajustar periodicamente o modelo diante da deriva.

Referências

[1] BRUCK, J. On the convergence properties of the Hopfield model. **Proceedings of the IEEE**, v. 78, n. 10, p. 1579–1585, 1990. DOI: https://doi.org/10.1109/5.58341.

[2] BRUCK, J.; ROYCHOWDHURY, V. P. On the number of spurious memories in the Hopfield model. **IEEE Transactions on Information Theory**, v. 36, n. 2, p. 393–397, 1990. DOI: https://doi.org/10.1109/18.52486.

[3] CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly detection: a survey. **ACM Computing Surveys**, v. 41, n. 3, art. 15, 2009. DOI: https://doi.org/10.1145/1541880.1541882.

[4] DEMIRCIGIL, M. *et al.* On a model of associative memory with huge storage capacity. **Journal of Statistical Physics**, v. 168, n. 2, p. 288–299, 2017. DOI: https://doi.org/10.1007/s10955-017-1806-y.

[5] FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006. DOI: https://doi.org/10.1016/j.patrec.2005.10.010.

[6] HERTZ, J.; KROGH, A.; PALMER, R. G. **Introduction to the Theory of Neural Computation**. Redwood City: Addison-Wesley, 1991.

[7] HOPFIELD, J. J. Neural networks and physical systems with emergent collective computational abilities. **Proceedings of the National Academy of Sciences (PNAS)**, v. 79, n. 8, p. 2554–2558, 1982. DOI: https://doi.org/10.1073/pnas.79.8.2554.

[8] HOPFIELD, J. J. Neurons with graded response have collective computational properties like those of two-state neurons. **Proceedings of the National Academy of Sciences (PNAS)**, v. 81, n. 10, p. 3088–3092, 1984. DOI: https://doi.org/10.1073/pnas.81.10.3088.

[9] HOPFIELD, J. J.; TANK, D. W. "Neural" computation of decisions in optimization problems. **Biological Cybernetics**, v. 52, n. 3, p. 141–152, 1985. DOI: https://doi.org/10.1007/BF00339943.

[10] KIM, S.; CHOI, K.; CHOI, H.-S.; LEE, B.; YOON, S. Towards a rigorous evaluation of time-series anomaly detection. **Proceedings of the AAAI Conference on Artificial Intelligence**, v. 36, n. 7, p. 7194–7201, 2022. DOI: https://doi.org/10.1609/aaai.v36i7.20680.

[11] KROTOV, D.; HOPFIELD, J. J. Dense associative memory for pattern recognition. In: **Advances in Neural Information Processing Systems 29 (NeurIPS 2016)**, 2016, p. 1172–1180. arXiv:1606.01164.

[12] MCELIECE, R. J.; POSNER, E. C.; RODEMICH, E. R.; VENKATESH, S. S. The capacity of the Hopfield associative memory. **IEEE Transactions on Information Theory**, v. 33, n. 4, p. 461–482, 1987. DOI: https://doi.org/10.1109/TIT.1987.1057328.

[13] ML-JKU. **hopfield-layers**: código-fonte das camadas Hopfield, indicado por Ramsauer *et al.* (2021). Disponível em: https://github.com/ml-jku/hopfield-layers.

[14] NETMANAIOPS. **OmniAnomaly**: código e *Server Machine Dataset* (SMD). Repositório do GitHub (licença MIT declarada no repositório). Disponível em: https://github.com/NetManAIOps/OmniAnomaly. Acesso em: 6 nov. 2026.

[15] PEDREGOSA, F. *et al.* Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

[16] RAMSAUER, H. *et al.* Hopfield networks is all you need. In: **International Conference on Learning Representations (ICLR)**, 2021. arXiv:2008.02217.

[17] SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. **PLOS ONE**, v. 10, n. 3, e0118432, 2015. DOI: https://doi.org/10.1371/journal.pone.0118432.

[18] STORKEY, A. J. Increasing the capacity of a Hopfield network without sacrificing functionality. In: **Artificial Neural Networks — ICANN'97**. Lecture Notes in Computer Science. Berlin: Springer, 1997, p. 451–456. DOI: https://doi.org/10.1007/BFb0020196.

[19] SU, Y. *et al.* Robust anomaly detection for multivariate time series through stochastic recurrent neural network. In: **Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '19)**. ACM, 2019. DOI: https://doi.org/10.1145/3292500.3330672.

[20] TRABALHO de Implementação de Redes Neurais Artificiais: descrição do trabalho. Documento da disciplina fornecido pelo professor (PDF), [s.d.].

[21] WIKIPEDIA. **Hopfield network**. Material fornecido pelo professor (impressão de 14 out. 2026; versão `oldid=1377477270`). Disponível em: https://en.wikipedia.org/wiki/Hopfield_network.

A Pseudocódigos e notas de implementação

Os algoritmos usam a notação da Seção 2: N neurônios, K padrões, estados em $\{-1,+1\}^N$ e limiares $\theta = 0$. Descrevem o projeto da implementação; o código dos experimentos não faz parte desta versão do relatório.

Algoritmo 1 Armazenamento de K padrões (regra de Hebb ou de Storkey).

Entrada: padrões $\xi^1, \dots, \xi^K \in \{-1,+1\}^N$; regra $\in \{\text{Hebb}, \text{Storkey}\}$
Saída: $W \in \mathbb{R}^{N\times N}$ simétrica, com $w_{ii} = 0$

$W \leftarrow 0$
para $\nu = 1, \dots, K$ **faça**
  se regra = Hebb **então**
    $W \leftarrow W + \frac{1}{N}\,\xi^\nu \xi^{\nu\top}$ ▷ Eq. (2.3)
  senão
    $u \leftarrow W\xi^\nu$
    $W \leftarrow W + \frac{1}{N}(\xi^\nu\xi^{\nu\top} - \xi^\nu u^\top - u\,\xi^{\nu\top} + 2W)$ ▷ Eq. (2.4)
  fim se
  zerar a diagonal de W
fim para
retorne W

Forma matricial da regra de Storkey. Como $w_{ii} = 0$, o campo local que exclui i e j é $h^\nu_{ij} = \sum_{k\neq i,j} w_{ik}\xi^\nu_k = u_i - w_{ij}\xi^\nu_j$, com $u = W^{\nu-1}\xi^\nu$, e analogamente $h^\nu_{ji} = u_j - w_{ji}\xi^\nu_i$. Usando

$(\xi_i^\nu)^2 = (\xi_j^\nu)^2 = 1$ e $w_{ij} = w_{ji}$,

$$\xi_i^\nu h_{ji}^\nu + \xi_j^\nu h_{ij}^\nu = \xi_i^\nu u_j + u_i \xi_j^\nu - 2w_{ij}^{\nu-1},$$

e a recursão (2.4) fica, para $i \neq j$, $w_{ij}^\nu = w_{ij}^{\nu-1} + \frac{1}{N}(\xi_i^\nu \xi_j^\nu - \xi_i^\nu u_j - u_i \xi_j^\nu + 2w_{ij}^{\nu-1})$, que é a forma matricial do Algoritmo 1 fora da diagonal; a diagonal é zerada depois de cada padrão. Conferimos a equivalência numericamente: com $N = 40$ e $K = 6$ padrões aleatórios, a diferença máxima entre a recursão elemento a elemento e a forma matricial foi da ordem de 10^{-16}.

Algoritmo 2 Recuperação assíncrona (rede clássica).

Entrada: W (com $\theta = 0$); estado inicial $s^0 \in \{-1, +1\}^N$; número máximo de varreduras $T_{\max}$
Saída: estado final s^*; número T de varreduras com ao menos uma troca

$s \leftarrow s^0$; $\quad T \leftarrow 0$
para $t = 1, \ldots, T_{\max}$ **faça**
  sortear uma permutação π de $\{1, \ldots, N\}$; $\quad$ mudou $\leftarrow$ falso
  para todo k na ordem de π **faça**
    $h \leftarrow \sum_j w_{kj} s_j$
    $s'_k \leftarrow +1$ se $h \geq 0$ e $s'_k \leftarrow -1$ caso contrário ▷ Eq. (2.1)
    se $s'_k \neq s_k$ **então**
      $s_k \leftarrow s'_k$; $\quad$ mudou $\leftarrow$ verdadeiro
    fim se
  fim para
  se não mudou **então**
    interromper
  fim se
  $T \leftarrow T + 1$
fim para
retorne (s, T)

Algoritmo 3 Detector *one-class* com a rede de Hopfield clássica.

Entrada: S_{aj} e S_{cal} (treino sem rótulos); níveis b; número K de protótipos; regra de armazenamento; taxa α; $T_{\max}$; escore $a \in \{S_1, \ldots, S_6\}$ (Tabela 7)
Saída: para cada observação x, o escore $a(x)$ e o rótulo previsto $\hat{y}$

Ajuste (uma vez por máquina)
determinar os limiares do termômetro e os atributos constantes em S_{aj} ▷ Seção 4.3
escolher K medoides $\xi^1, \ldots, \xi^K$ entre os códigos de S_{aj}, no espaço de Hamming ▷ Seção 4.4
$W \leftarrow$ Algoritmo 1$(\xi^1, \ldots, \xi^K)$
$\tau \leftarrow$ quantil de ordem $1 - \alpha$ de $\{a(x) : x \in S_{\text{cal}}\}$, com $a(x)$ calculado como abaixo
Decisão (por observação x)
$s^0 \leftarrow \text{cod}(x)$
$(s^*, T) \leftarrow$ Algoritmo 2$(W, s^0, T_{\max})$
calcular $a(x)$ a partir de s^0, s^*, T e dos protótipos
retorne $a(x)$ e $\hat{y} = \mathbf{1}[a(x) > \tau]$

Notas de implementação.

- **Estabilidade numérica (rede moderna):** lse e softmax são calculados subtraindo o máximo de $\beta X^\top \xi$, para evitar estouro numérico com β grande.

Algoritmo 4 Recuperação e escores da rede de Hopfield moderna.

Entrada: memória $X \in \mathbb{R}^{N\times K}$ (padrões nas colunas); $M = \max_i \|x_i\|$; $\beta > 0$; consulta $\xi^0 \in \mathbb{R}^N$; número de atualizações $T \geq 1$ ($T = 1$ por padrão)
Saída: estado final ξ^T; energia $E(\xi^0)$; resíduo r; entropia H

$p \leftarrow \mathrm{softmax}(\beta X^\top \xi^0)$
$E_0 \leftarrow -\operatorname{lse}(\beta, X^\top \xi^0) + \frac{1}{2}\xi^{0\top}\xi^0 + \beta^{-1}\ln K + \frac{1}{2}M^2$ ▷ Eq. (2.7)
$H \leftarrow -\sum_i p_i \ln p_i$
para $t = 1, \ldots, T$ **faça**
    $\xi^t \leftarrow X\,\mathrm{softmax}(\beta X^\top \xi^{t-1})$ ▷ Eq. (2.8)
fim para
$r \leftarrow \|\xi^0 - \xi^1\|$
retorne ξ^T, E_0, r, H

- **Vetorização:** a regra de Storkey e as distâncias de Hamming aos protótipos usam produtos matriciais; em estados ± 1, $d_{\mathrm{H}}(a, b) = \frac{1}{2}(N - a^\top b)$.
- **Ordem de atualização:** a ordem aleatória de cada varredura é gerada por uma semente fixada, e os resultados são repetidos com 3 sementes (Seção 4.7).
- **Empates:** $h_k = 0$ leva a $+1$, conforme a Eq. (2.1); a Proposição 2.2 cobre esse caso.

Tabela 20. Custo aproximado por operação (T: número de varreduras ou atualizações; K: padrões armazenados).

Operação	Clássica (Hebb/Storkey)	Moderna
Armazenar K padrões	$O(KN^2)$	$O(NK)$ (guardar X)
Memória	$O(N^2)$	$O(NK)$
Uma varredura / atualização	$O(N^2)$	$O(NK)$
Recuperação completa	$O(TN^2)$	$O(TNK)$
Escores de distância aos protótipos	$O(NK)$	—

B Exemplo numérico com 5 neurônios

O exemplo abaixo, calculado à mão e conferido numericamente, mostra a recuperação e os escores da Tabela 7 em uma rede com um único padrão armazenado, $\xi = (+1, -1, +1, -1, +1)$ e $N = 5$. Para simplificar, $W = \xi\xi^\top - I$ (regra de Hebb sem o fator $1/N$ da Eq. (2.3), o que não altera a dinâmica com $\theta = 0$; com o fator, todas as energias ficam divididas por $N = 5$). Assim $w_{ij} = \xi_i\xi_j$ para $i \neq j$ e $w_{ii} = 0$.

Energia em função da sobreposição. Como $\sum_{i,j}\xi_i\xi_j s_i s_j = (\xi \cdot s)^2$ e os termos diagonais somam N,

$$E(s) = -\tfrac{1}{2}s^\top W s = -\tfrac{1}{2}\big[(\xi \cdot s)^2 - N\big].$$

O padrão armazenado tem $\xi \cdot \xi = 5$ e $E(\xi) = -\frac{1}{2}(25 - 5) = -10$.

Consulta com um bit diferente. Seja $s^0 = (+1, -1, -1, -1, +1)$, que difere de ξ no neurônio 3, com $\xi \cdot s^0 = 3$ e $E(s^0) = -\frac{1}{2}(9 - 5) = -2$. O campo local de cada neurônio é $h_i = \sum_{j\neq i}\xi_i\xi_j s_j = \xi_i(\xi \cdot s) - s_i$:

Neurônio i	1	2	3	4	5
ξ_i	$+1$	-1	$+1$	-1	$+1$
s_i^0	$+1$	-1	-1	-1	$+1$
$h_i = 3\xi_i - s_i^0$	2	-2	4	-2	2
$\operatorname{sgn}(h_i)$	$+1$	-1	$+1$	-1	$+1$
s_i^*	$+1$	-1	$+1$	-1	$+1$

Só o neurônio 3 muda: $s_3^0 = -1$ e $h_3 = 4 > 0$. Qualquer que seja a ordem de visita, o resultado é o mesmo: $s^* = \xi$, em uma varredura com troca (mais uma sem troca, que confirma o ponto fixo). A variação de energia da troca é $-(s_3' - s_3)h_3 = -2 \cdot 4 = -8$, de -2 para -10, como previsto pela demonstração da Proposição 2.2.

Consulta igual ao padrão invertido. Com $s^0 = -\xi$, $\xi \cdot s^0 = -5$ e $h_i = -5\xi_i - s_i^0 = -4\xi_i = 4s_i^0$: cada neurônio já concorda com o sinal do seu campo, e $-\xi$ é um ponto fixo com $E(-\xi) = -10 = E(\xi)$, porque a energia é par em s quando $\theta = 0$. A rede não reconhece nada de errado; só os escores que medem a distância *com sinal* aos protótipos, S_2 e S_5, denunciam o padrão invertido.

Tabela 21. Escores do exemplo (Tabela 7). Quanto maior, mais anômalo; S_3 e S_4 têm a escala da energia sem o fator $1/N$.

Consulta s^0	S_1	S_2	S_3	S_4	S_5	S_6
ξ (padrão armazenado)	0	0	-10	0	0	0
$(+1,-1,-1,-1,+1)$ (1 bit diferente)	0,2	0,2	-2	8	0	1
$-\xi$ (padrão invertido)	0	1	-10	0	1	0

A Tabela 21 resume a lição: S_1, S_3 e S_4 (que dependem só da dinâmica e da energia) dão valores indistinguíveis dos do padrão armazenado para $-\xi$; por isso o detector usa também S_2 e S_5.

C *Prompt* e registro da Etapa II

O enunciado pede que o *prompt* e a versão do modelo sejam documentados [20]. Esta seção fixa o *prompt* antes da execução. O texto é em inglês e usa apenas caracteres ASCII, para evitar problemas de codificação em APIs; os campos entre chaves são preenchidos pelo código.

C.1 Mensagens

```
=== SYSTEM MESSAGE ===
You are an expert in server monitoring and anomaly detection.

You will receive one observation of a server: 38 anonymous
resource-utilization and activity metrics, named m1 to m38. Every value is
scaled to the range [0, 1]. Metrics are sampled once per minute. Their names
and units are not available.

Task: decide whether the observation belongs to an anomalous period (a server
incident) or to normal operation.

Rules:
- Use only the information given in this conversation.
- Anomalies are rare: roughly 4 out of every 100 observations.
```

```
- Reply with one JSON object and nothing else:
  {"label": 0 or 1, "score": a number between 0 and 1}
  label = 1 if the observation is anomalous, 0 if it is normal.
  score = your confidence that the observation is anomalous
          (0 = certainly normal, 1 = certainly anomalous).

=== USER MESSAGE, zero-shot ===
Observation:
{observation}

=== USER MESSAGE, few-shot (k = 3, 5, 10 or 20 labeled examples) ===
Labeled examples from the same kind of server (k = {k}):

Example 1:
{observation_1}
Answer: {"label": 0, "score": 0.0}

Example 2:
{observation_2}
Answer: {"label": 1, "score": 1.0}

... (up to Example {k}, in random order)

Now classify this observation:
{observation}

=== OPTIONAL BLOCK, reference profile (zero-shot variant) ===
Typical values of each metric during normal operation of this server
(median / 95th percentile):
m1: {median_1} / {p95_1}
...
m38: {median_38} / {p95_38}
```

C.2 Serialização das observações

Cada observação é escrita em uma linha, com os 38 valores no formato `mj=v`, separados por espaço e com 4 casas decimais. O exemplo abaixo é a linha 15.000 do arquivo de teste da máquina 1-1 (rótulo 0), quebrada em cinco linhas apenas para caber na página; no *prompt*, é uma linha só. A linha 16.100 da mesma máquina (rótulo 1) começa com `m1=0.5161`, acima do máximo de treino do atributo (0,4946), e serve de exemplo de observação anômala (Seção 3.3). Ambas são ilustrações da *forma* do texto, não exemplos do protocolo.

```
m1=0.0968 m2=0.0794 m3=0.0702 m4=0.0627 m5=0.0000 m6=0.8974 m7=0.2750 m8=0.0000
m9=0.0288 m10=0.0000 m11=0.1066 m12=0.1081 m13=0.0274 m14=0.0575 m15=0.1250 m16=0.1246
m17=0.0000 m18=0.0000 m19=0.1483 m20=0.1009 m21=0.1254 m22=0.0984 m23=0.8330 m24=0.0126
m25=0.0493 m26=0.0117 m27=0.0000 m28=0.1029 m29=0.0000 m30=0.0201 m31=0.0897 m32=0.0839
m33=0.0004 m34=0.0001 m35=0.0810 m36=0.0811 m37=0.0000 m38=0.0000
```

C.3 Regras de execução

- **Exemplos:** para cada par $(k, \text{semente})$ sorteia-se de L_{tr} uma lista fixa de k exemplos, com $k = 3$: 2 normais e 1 anômalo; $k = 5$: 3+2; $k = 10$: 5+5; $k = 20$: 10+10, em ordem aleatória. A mesma lista é usada para todas as observações da execução, o que permite o uso de *prompt caching*, se a API o oferecer.

- **Parâmetros:** temperatura 0 (ou a menor disponível) e limite curto de *tokens* de saída; usar o modo de saída JSON quando existir.
- **Respostas inválidas:** se a resposta não for um JSON válido, repete-se a chamada uma vez; persistindo o erro, a observação conta como rótulo 0 e escore 0, e a taxa de respostas inválidas é reportada.
- **Escore:** o escore autodeclarado não é calibrado, de modo que a AUC-ROC calculada sobre ele é apenas indicativa. Se a API fornecer *logprobs*, a probabilidade do *token* do rótulo é uma alternativa.
- **Número de chamadas:** para n observações por máquina, são $3 \times [1 + 4 \times 3] \times n = 39\,n$ chamadas (3 máquinas, 1 configuração *zero-shot* e 4 valores de k com 3 sementes cada); por exemplo, 19.500 chamadas com $n = 500$. O custo total segue de multiplicar esse número pelos *tokens* médios por chamada e pelos preços da Tabela 22.
- **Contaminação:** o SMD é público desde 2019 [19, 14], e não é possível excluir que faça parte dos dados de pré-treinamento do modelo; isso deve ser mencionado na discussão.

C.4 Registro da execução

Tabela 22. Registro da Etapa II (preencher durante a execução).

Campo	Valor
Provedor e modelo	**[a preencher]**
Identificador exato da versão (cadeia da API)	**[a preencher]**
Data(s) de execução	**[a preencher]**
Temperatura e limite de *tokens* de saída	0 e valor curto (proposta); valores usados: **[a preencher]**
Observações avaliadas por máquina (n)	500 a 2.000 (proposta); valor usado: **[a preencher]**
Tokens médios por chamada (entrada / saída)	**[a preencher]**
Preço por milhão de *tokens* (entrada / saída)	**[a preencher]**
Tempo por 100 amostras	**[a preencher]**
Custo estimado por 100 amostras	**[a preencher]**
Respostas inválidas (%)	**[a preencher]**

D Cronograma proposto

As apresentações remotas ocorrem em 02 e 04/12 [20]. O enunciado não informa a data de entrega do relatório, nem em qual dos dois dias cada equipe apresenta; o plano abaixo é uma **proposta**, que supõe a entrega do relatório e dos *slides* até a véspera da primeira apresentação (01/12), e deve ser confirmada com o professor.

Divisão de tarefas (equipe de até 3 integrantes).

- **Integrante A** (**[a preencher: nome]**): dados, divisões, linhas de base clássicas e métricas.
- **Integrante B** (**[a preencher: nome]**): rede de Hopfield (clássica e moderna), E1 e ablações.
- **Integrante C** (**[a preencher: nome]**): Etapa II (*prompt*, execução e custo) e revisão do texto.

Tabela 23. Cronograma proposto (datas de 2026).

	Período	Atividades	Entrega
1	06–13/11	Confirmar com o professor o uso da rede de Hopfield como modelo do tema, as linhas de base e as datas; dividir as tarefas; baixar o SMD (registrar o *commit*); implementar leitura, divisões e codificação em termômetro; implementar Hebb, Storkey, recuperação e escores; executar E1a.	Dados e rede clássica validados em E1a
2	16–20/11 (20/11: feriado)	Seleção de protótipos e E1b; detector nas máquinas 1-3, 2-5 e 3-6; linhas de base (*Random Forest*, SVM, OC-SVM e k-NN); escolha do limiar em L_{val}.	Primeiros resultados da Etapa I nas 3 máquinas
3	23–27/11	Protocolo S (18 máquinas) e Protocolo U (28); ablações; rede moderna (β); Etapa II (*zero-shot* e *few-shot*, com registro de tempo e custo); preencher a Seção 5.	Seção 5 completa
4	30/11–01/12	Revisar as Seções 6 e 7 e o resumo à luz dos resultados; conferir as referências; preparar os *slides* e ensaiar.	Relatório e *slides*
5	02 e 04/12	Apresentação remota.	—

Riscos e mitigação.

- **Hopfield próximo do acaso:** o resultado é registrado e analisado como achado (ablações e Seção 6); a comparação crítica vale igualmente.
- **Prazo apertado:** priorizar o Protocolo S nas 3 máquinas representativas e estender às 18 depois.
- **Custo ou latência da API:** reduzir n, usar o modelo mais barato disponível e limitar $k = 20$ a uma semente.
- **Modelo fora da lista do enunciado:** a confirmação com o professor é a primeira atividade do cronograma.

E Conformidade com o enunciado

A Tabela 24 relaciona cada exigência do enunciado [20] ao local do relatório e ao seu estado. **Pronto**: texto ou dados concluídos nesta versão; **Parcial**: método, critérios e formato de relato fixados, mas a evidência depende dos experimentos; **Pendente**: ainda a fazer.

Tabela 24. Exigências do enunciado, local no relatório e estado.

Exigência	Onde	Estado
Escolha do problema e da base de dados; tipo (classificação)	Seções 3.1 e 3.2	**Pronto**: classificação binária por ponto no SMD
Definições do problema e do conjunto de treinamento	Seções 3.1 e 3.2	**Pronto**
2 a 3 exemplos da base de dados	Seção 3.3	**Pronto**: 3 observações reais da máquina 1-1
Valores desejados e atributos	Seções 3.1 e 3.2	**Pronto**: rótulo 0/1 e 38 atributos
Quantidade de amostras	Seção 3.2; Apêndice G	**Pronto**
Preparação e limpeza	Seção 4.2	**Pronto**
Balanceamento de classes	Seção 4.8	**Pronto**

continua na próxima página

Exigência	Onde	Estado
Divisão dos conjuntos	Seção 4.7	**Pronto**
Métricas de avaliação	Seção 4.9	**Pronto**
Etapa I: ao menos 2 modelos de classificação	Seção 4.6; Seção 5	**Parcial**: protocolo definido, execução pendente; o Hopfield não consta da lista do enunciado (confirmar com o professor)
Métricas mínimas: acurácia, precisão, revocação, F-scores, AUC-ROC e matriz de confusão	Seção 4.9; Tabelas 12 e 13	**Parcial**: formato fixado, valores pendentes
Etapa II: classificação por *prompting* (descrição da tarefa, *zero-shot*, *few-shot* com $\{3, 5, 10, 20\}$)	Seção 4.11; Apêndice C	**Parcial**: *prompt* documentado, execução pendente
Etapa II: repetir as métricas; tempo por 100 amostras e custo estimado	Seção 4.11; Tabelas 17 e 22	**Parcial**: formato fixado, valores pendentes
Mesmos dados da Etapa I; documentar *prompt* e versão do modelo	Seção 4.11; Apêndice C	**Parcial**: *prompt* documentado, versão do modelo pendente
Comparação crítica (pontos positivos e negativos)	Seção 6	**Parcial**: critérios e análise *a priori* prontos, evidência empírica pendente
Conclusões: o que funciona, limites e próximos passos	Seção 7	**Parcial**: limites e próximos passos prontos; "o que funciona" depende dos experimentos
Equipe de no máximo 3 integrantes	Folha de rosto; Apêndice D	**Pendente**: nomes e instituição
Relatório técnico	Este documento	**Parcial**: estrutura completa, resultados pendentes
Apresentação remota (02 e 04/12)	Apêndice D	**Pendente**

F Derivações

As derivações abaixo são nossas (a menos de onde há citação) e complementam as seções 2 e 4.

F.1 Energia de Hebb em função das sobreposições

Com $w_{ij} = \frac{1}{N}\sum_\mu \xi_i^\mu \xi_j^\mu$ para $i \neq j$, $w_{ii} = 0$, $\theta = 0$ e a sobreposição $m_\mu(s) = \frac{1}{N}\,\xi^\mu \cdot s$, como $(\xi_i^\mu s_i)^2 = 1$,

$$E(s) = -\tfrac{1}{2}\sum_{i\neq j} w_{ij} s_i s_j = -\frac{1}{2N}\sum_{\mu=1}^{K}\Big[\Big(\sum_i \xi_i^\mu s_i\Big)^2 - \sum_i (\xi_i^\mu s_i)^2\Big] = -\frac{N}{2}\sum_{\mu=1}^{K} m_\mu(s)^2 + \frac{K}{2}.$$

Consequências: (i) E depende de s só pelas sobreposições, e seus mínimos são estados com $|m_\mu|$ grande; (ii) $E(-s) = E(s)$, de modo que $-\xi^\mu$ é tão profundo quanto ξ^μ; (iii) se os outros padrões são quase ortogonais a ξ^ν, $E(\xi^\nu) \approx -\frac{N}{2} + \frac{K}{2}$. A energia da CAM de Hopfield e Tank [9, Eq. 5], $-\frac{1}{2}\sum_s (V^s \cdot V)^2$, é N vezes a nossa a menos de uma constante aditiva, com mínimos de profundidade $\approx -\frac{1}{2}N^2$.

F.2 Ruído cruzado da regra de Hebb

Para o padrão armazenado ξ^ν, o campo local se decompõe em $h_i(\xi^\nu) = \frac{N-1}{N}\xi_i^\nu + \eta_i$, com $\eta_i = \frac{1}{N}\sum_{\mu\neq\nu}\sum_{j\neq i}\xi_i^\mu\xi_j^\mu\xi_j^\nu$. Se os padrões são independentes e não viesados, cada parcela $\xi_i^\mu\xi_j^\mu\xi_j^\nu$ ($\mu\neq\nu$, $j\neq i$) é uma variável ±1 uniforme e independente das demais (contém o fator ξ_j^μ, exclusivo do par (μ, j)). Logo $\mathbb{E}[\eta_i] = 0$ e $\mathrm{Var}[\eta_i] = \frac{(K-1)(N-1)}{N^2} \approx \frac{K-1}{N}$. Pelo teorema central do limite, o bit i é trocado no primeiro passo com probabilidade $\approx \Phi\big(-\sqrt{N/K}\big)$, em que Φ é a função de distribuição normal padrão. A Tabela 25 mostra a aproximação e o resultado de uma simulação ($N = 1000$, 20 repetições). É apenas uma estimativa do *primeiro passo* a partir de um padrão exato; o limite crítico de $0{,}138N$ vem de uma análise mais completa [6].

Tabela 25. Probabilidade de erro por bit no primeiro passo, a partir de um padrão armazenado (regra de Hebb, padrões aleatórios não viesados).

K/N	Desvio padrão do ruído $\sqrt{K/N}$	$\Phi(-\sqrt{N/K})$	Simulação
0,05	0,22	$3{,}9\times10^{-6}$	$5{,}0\times10^{-6}$
0,10	0,32	$7{,}8\times10^{-4}$	$7{,}0\times10^{-4}$
0,138	0,37	$3{,}6\times10^{-3}$	$3{,}5\times10^{-3}$
0,20	0,45	$1{,}3\times10^{-2}$	$1{,}3\times10^{-2}$

F.3 A energia da rede moderna como mínimo suave

Como $x_i^\top\xi = \frac{1}{2}\|x_i\|^2 + \frac{1}{2}\|\xi\|^2 - \frac{1}{2}\|\xi - x_i\|^2$,

$$\mathrm{lse}(\beta, X^\top\xi) = \beta^{-1}\ln\sum_i e^{\beta x_i^\top\xi} = \tfrac{1}{2}\|\xi\|^2 + \beta^{-1}\ln\sum_i e^{\frac{1}{2}\beta\|x_i\|^2}e^{-\frac{1}{2}\beta\|\xi-x_i\|^2}.$$

Em (2.7) o termo $\frac{1}{2}\xi^\top\xi$ se cancela, e

$$E(\xi) = -\beta^{-1}\ln\sum_i e^{\frac{1}{2}\beta\|x_i\|^2}e^{-\frac{1}{2}\beta\|\xi-x_i\|^2} + \beta^{-1}\ln K + \tfrac{1}{2}M^2.$$

Se $\|x_i\| = M$ para todo i, o fator $e^{\frac{1}{2}\beta M^2}$ sai da soma e cancela $\frac{1}{2}M^2$. Com $d_i = \frac{1}{2}\|\xi - x_i\|^2$,

$$E(\xi) = -\beta^{-1}\ln\Big[\frac{1}{K}\sum_{i=1}^{K} e^{-\beta d_i}\Big], \qquad \min_i d_i \;\le\; E(\xi) \;\le\; \frac{1}{K}\sum_i d_i.$$

A primeira desigualdade vem de $e^{-\beta d_i} \le e^{-\beta\min_j d_j}$ para todo i; a segunda, da desigualdade de Jensen. Quando $\beta\to\infty$, $E\to\min_i d_i$ (vizinho mais próximo); quando $\beta\to0$, $E\to\frac{1}{K}\sum_i d_i$, cujo mínimo em ξ é o centroide dos padrões. Além disso, $e^{-\beta E(\xi)} = \frac{1}{K}\sum_i \exp(-\|\xi - x_i\|^2/(2\sigma^2))$ com $\sigma^2 = 1/\beta$ é, a menos de uma constante, uma estimativa de densidade por kernel gaussiano, de modo que $E(\xi) = -\beta^{-1}\ln\hat{p}(\xi) + \mathrm{const}$.

F.4 Padrões binários: distância de Hamming e separação

Para $x, y \in \{-1, +1\}^N$, coordenadas iguais contribuem com $+1$ a $x^\top y$ e coordenadas diferentes, com -1; logo $x^\top y = N - 2d_{\mathrm{H}}(x, y)$, $\|x - y\|^2 = 4d_{\mathrm{H}}(x, y)$ e $\frac{1}{2}\|x - y\|^2 = 2d_{\mathrm{H}}(x, y)$. Para a separação $\Delta_i = x_i^\top x_i - \max_{j\neq i} x_i^\top x_j$ dos Teoremas 4 e 5 de Ramsauer et al. [16],

$$\Delta_i = N - \big(N - 2\min_{j\neq i} d_{\mathrm{H}}(x_i, x_j)\big) = 2\min_{j\neq i} d_{\mathrm{H}}(x_i, x_j).$$

Portanto, com protótipos binários, a energia moderna é um mínimo suave das distâncias de Hamming, $E(s) = -\beta^{-1} \ln\big[\frac{1}{K}\sum_i e^{-2\beta d_{\mathrm{H}}(s,x_i)}\big]$, e a facilidade de recuperar um protótipo depende da sua distância de Hamming ao protótipo mais próximo.

F.5 Distância de Hamming na codificação em termômetro

Para um atributo com limiares $\tau_1 < \cdots < \tau_{b'}$ (distintos, como na Seção 4.3), seja $r(x) = \#\{l : x > \tau_l\}$ o posto de x. Como os limiares são crescentes, $x > \tau_l$ se, e somente se, $l \le r(x)$, e o código é $(+1)^{r(x)}(-1)^{b'-r(x)}$. Para dois valores com postos $r \le r'$, os códigos diferem exatamente nas posições $r < l \le r'$, de modo que

$$d_{\mathrm{H}}(\mathrm{cod}(x), \mathrm{cod}(x')) = |r(x) - r(x')|.$$

A distância entre estados completos é a soma dessas diferenças de postos sobre os atributos, mais as discordâncias nos bits de novidade. Como os limiares são quantis empíricos do treino, $r(x)/(b+1)$ aproxima a função de distribuição empírica do atributo; assim a distância é invariante a reescalonamentos monótonos de cada atributo.

G Dados por máquina e divisão cronológica

A Tabela 26 traz, para cada uma das 28 máquinas do SMD, o tamanho de cada metade, as anomalias rotuladas, os cortes cronológicos da Seção 4.7 e a elegibilidade para os protocolos. Todos os números são de cálculo próprio a partir dos arquivos do repositório [14].

Tabela 26. Dados por máquina e divisão cronológica. **Linhas:** pontos de 1 minuto de cada metade. **Teste:** *Anôm.* é o número de pontos rotulados como anômalos, *%* a sua proporção e *Seg.* o número de segmentos anômalos contíguos. **Cortes:** $c_1 = \mathrm{round}(0{,}4n)$ e $c_2 = \mathrm{round}(0{,}6n)$, com n igual ao número de linhas de teste e índices a partir de 0; †: corte deslocado para uma zona sem anomalias. **Anomalias por bloco:** em L_{tr}, L_{val} e L_{te} (Eq. 4.1); a soma dos três blocos é igual a *Anôm.*, isto é, nenhuma anomalia cai nos embargos. **Elig.:** S = supervisionados e *one-class*; O = só *one-class*; — = nenhum (Tabela 8).

	Linhas		Teste			Cortes		Anomalias por bloco			
Máq.	Treino	Teste	Anôm.	%	Seg.	c_1	c_2	L_{tr}	L_{val}	L_{te}	Elig.
1-1	28.479	28.479	2.694	9,46	8	11.392	16.903†	0	546	2.148	O
1-2	23.694	23.694	542	2,29	10	9.478	14.216	140	0	402	—
1-3	23.702	23.703	817	3,45	12	9.481	14.222	86	281	450	S
1-4	23.706	23.707	720	3,04	12	9.483	14.224	85	279	356	S
1-5	23.705	23.706	100	0,42	7	9.482	14.224	0	73	27	O
1-6	23.688	23.689	3.708	15,65	30	9.476	14.213	472	27	3.209	S
1-7	23.697	23.697	2.398	10,12	13	9.479	14.218	2.247	41	110	S
1-8	23.698	23.699	763	3,22	20	9.480	14.219	477	16	270	S
2-1	23.693	23.694	1.170	4,94	13	9.478	14.216	122	34	1.014	S
2-2	23.699	23.700	2.833	11,95	11	9.480	14.220	0	11	2.822	O
2-3	23.688	23.689	269	1,14	10	9.476	14.213	104	30	135	S
2-4	23.689	23.689	1.694	7,15	20	9.413†	14.213	310	67	1.317	S
2-5	23.688	23.689	980	4,14	21	9.476	14.213	314	39	627	S
2-6	28.743	28.743	424	1,48	8	11.497	17.246	78	128	218	S
2-7	23.696	23.696	417	1,76	20	9.478	14.218	27	33	357	S
2-8	23.702	23.703	161	0,68	1	9.481	14.222	0	0	161	—
2-9	28.722	28.722	1.755	6,11	10	11.489	17.346†	0	992	763	O

continua na próxima página

Tabela 26 (continuação)

	Linhas		Teste			Cortes		Anomalias por bloco			
Máq.	Treino	Teste	Anôm.	%	Seg.	c_1	c_2	L_{tr}	L_{val}	L_{te}	Elig.
3-1	28.700	28.700	308	1,07	4	11.480	17.220	183	0	125	—
3-2	23.702	23.703	1.109	4,68	10	9.481	14.222	873	127	109	S
3-3	23.703	23.703	632	2,67	26	9.481	14.222	52	15	565	S
3-4	23.687	23.687	977	4,12	8	9.475	14.212	865	20	92	S
3-5	23.690	23.691	426	1,80	11	9.476	14.215	155	3	268	S
3-6	28.726	28.726	1.194	4,16	11	11.490	17.236	174	437	583	S
3-7	28.705	28.705	434	1,51	5	11.431†	17.223	35	81	318	S
3-8	28.703	28.704	1.371	4,78	6	11.482	17.336†	0	908	463	O
3-9	28.713	28.713	303	1,06	4	11.485	17.228	202	0	101	—
3-10	23.692	23.693	1.047	4,42	13	9.477	14.216	188	312	547	S
3-11	28.695	28.696	198	0,69	3	11.478	17.218	0	0	198	—
Total	708.405	708.420	29.444	4,16	327	—	—	7.189	4.500	17.755	—